Routing część 1: adresowanie

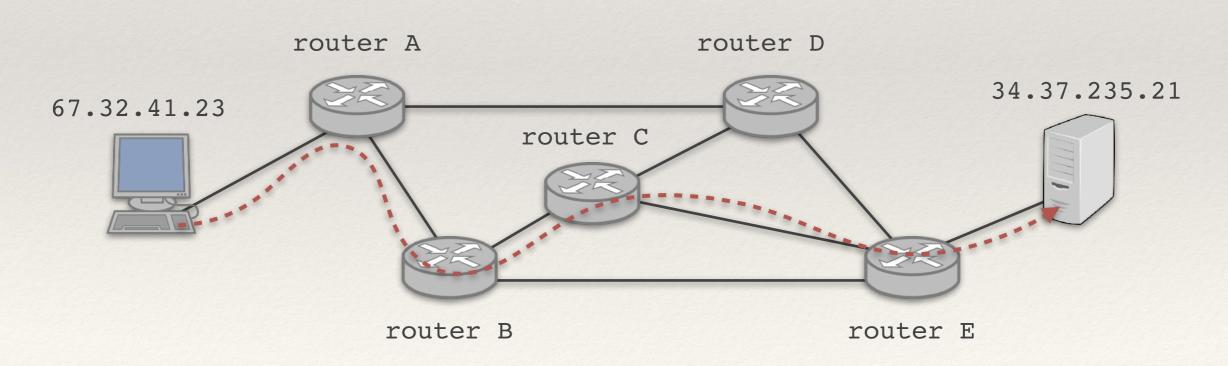
Sieci komputerowe Wykład 2

Marcin Bieńkowski

W poprzednim odcinku

Jak przesyłać dane przez sieć

- Chcemy przesyłać między aplikacjami strumień danych.
- * Globalne adresowanie: w Internecie każda karta sieciowa ma unikatowy 4-bajtowy adres IP.
- * Warstwa sieciowa zapewnia globalne dostarczanie danych pomiędzy dwoma dowolnymi kartami sieciowymi = interfejsami sieciowymi.



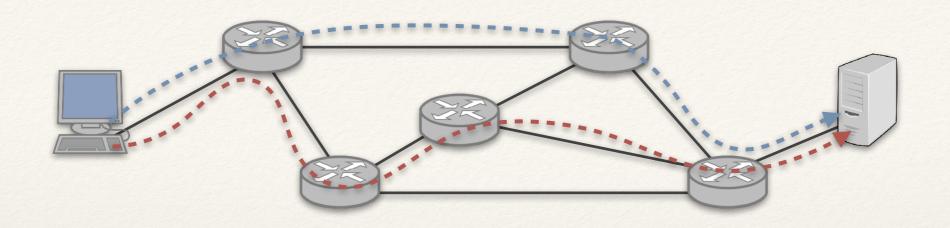
Przełączanie pakietów

* Wysyłany strumień danych dzielimy na małe porcje: pakiety.

nagłówek pakietu pakietu

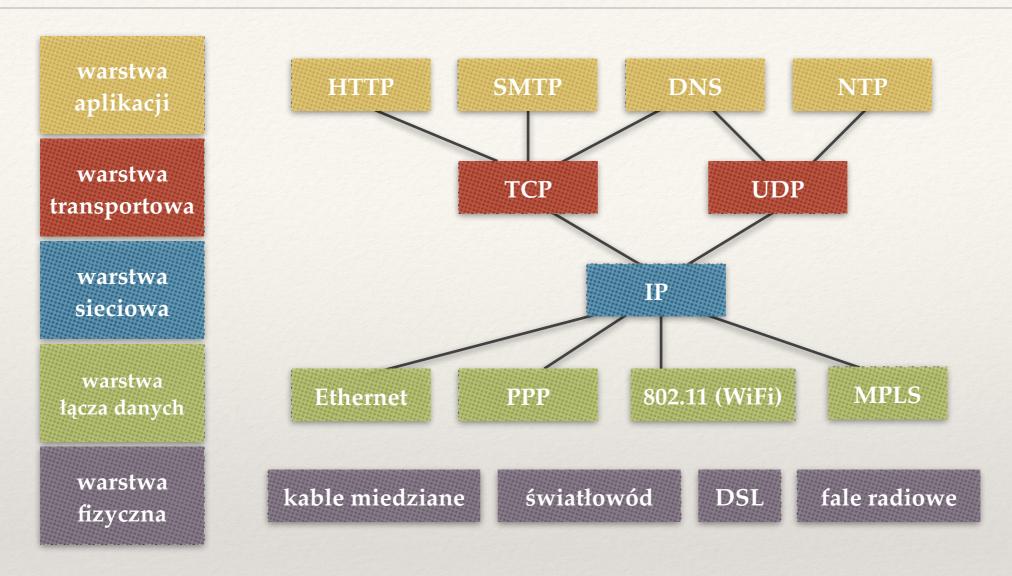
- Dane pakietu = fragment strumienia danych.
- * Nagłówek pakietu = informacje kontrolne, m.in. adres źródłowy i docelowy.
- * Każdy pakiet przesyłany niezależnie.

Routing



- * Routing (trasowanie) = wybór trasy dla danego pakietu.
- * W Internecie:
 - * Router tylko przekazuje pakiet dalej.
 - * Router nie wie nic o oryginalnym strumieniu danych.
 - * Router podejmuje decyzję na podstawie nagłówka pakietu w oparciu o tablice routingu.

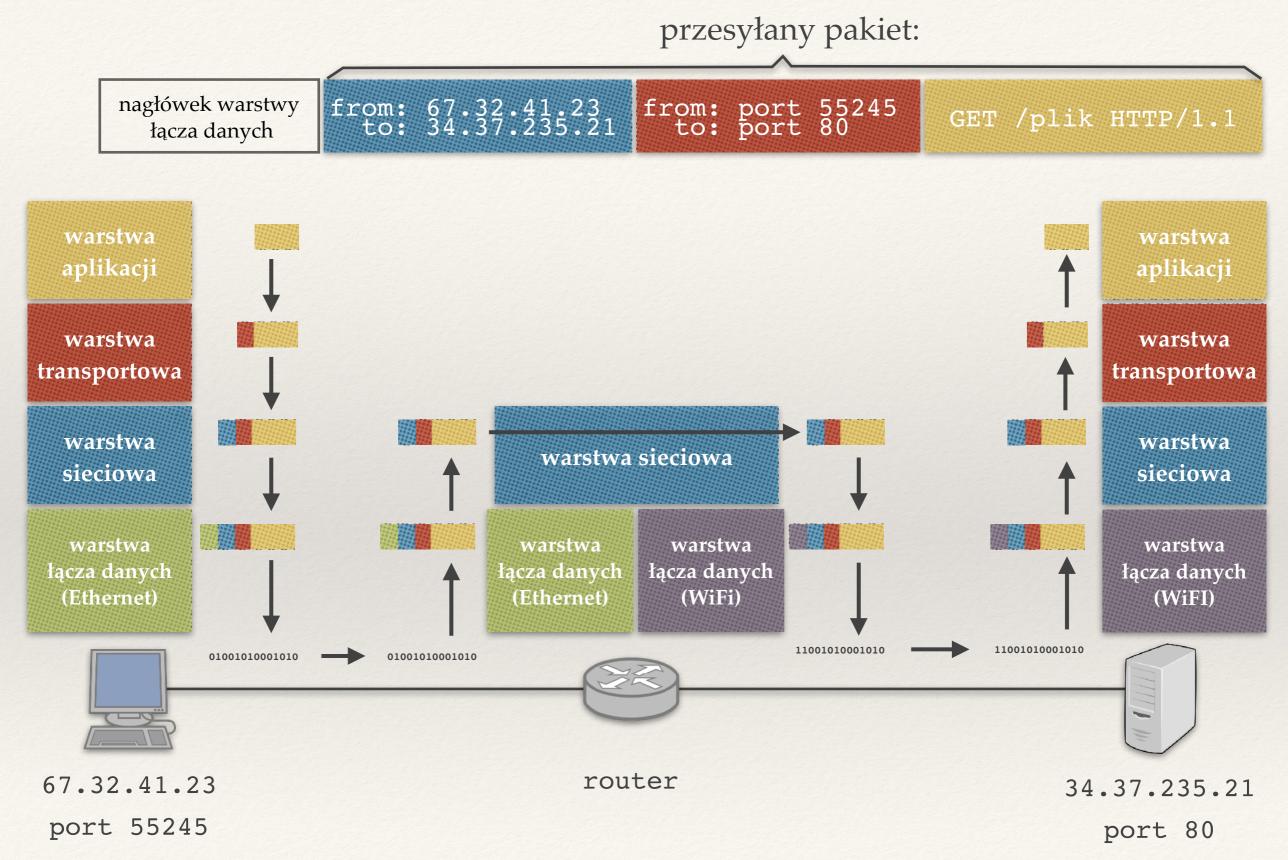
Protokoły w Internecie



Warstwa sieciowa w Internecie: tylko jeden protokół (IP)

- * Zaimplementowany na każdym urządzeniu.
- Definiuje zawodną, bezpołączeniową usługę umożliwiającą przesłanie pakietu między dwoma dowolnymi urządzeniami w sieci.

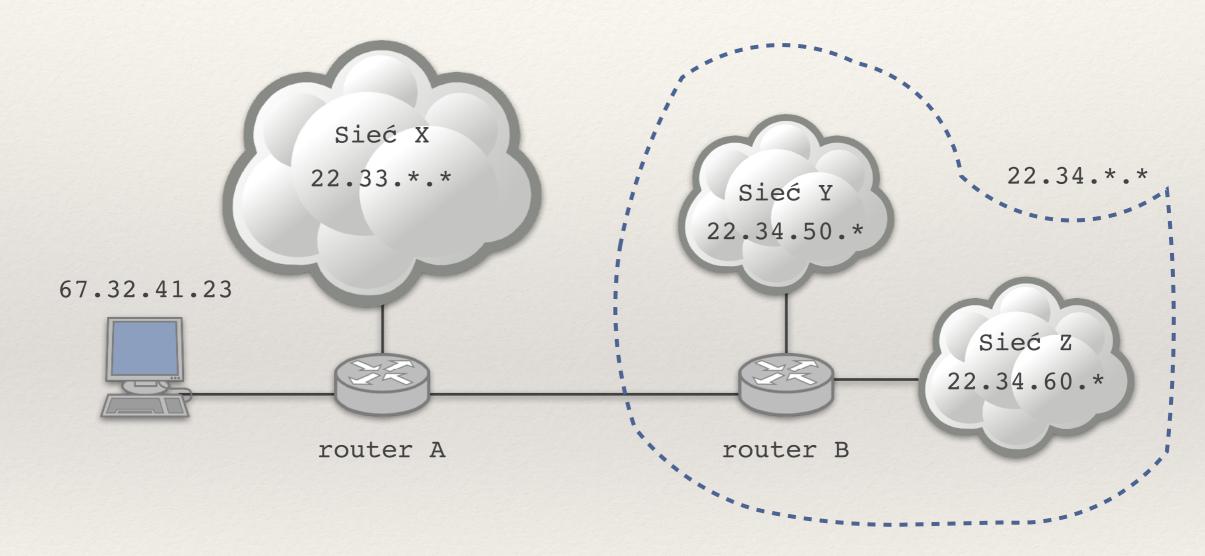
Internetowy model warstwowy



Adresowanie

Adresy IP

- * Każda karta sieciowa ma unikatowy 4-bajtowy adres.
- * Hierarchiczna struktura adresów:



* Router A nie musi znać trasy do sieci Y i Z osobno; wystarczy, że wie że pakiety do 22.34.*.* powinien wysyłać do routera B.

CIDR (1)

- Notacja CIDR (Classless Inter-Domain Routing): opisuje zakres adresów IP posiadających wspólny prefiks za pomocą pary (pierwszy adres z zakresu, długość prefiksu).
- * Przykład: adresy IP zaczynające się od prefiksu 10011100.00010001.0000100.0010
 - * pierwszy adres z zakresu: 10011100.00010001.00000100.00100000 = 156.17.4.32
 - długość prefiksu: 28 bitów
 - * zapis: 156.17.4.32/28

CIDR (2)

```
Przykład 1: 156.17.4.32/28 = adresy zaczynające się od prefiksu 156.17.4.0010:
```

- * **156.17.4.0010**0000 = 156.17.4.32 (pierwszy adres)
- * **156.17.4.0010**0001 = 156.17.4.33 (drugi adres)
- ***** ...
- * **156.17.4.0010**1110 = 156.17.4.46 (przedostatni adres)
- * **156.17.4.0010**1111 = 156.17.4.47 (ostatni adres)

Razem: $2^{32-28} = 2^4 = 16$ adresów.

Przykład 2: 0.0.0.0/0 = wszystkie adresy IP

Przykład 3: 34.56.78.90/32 = jeden konkretny adres IP

CIDR a sieci

Notację CIDR najczęściej stosujemy, żeby opisać konkretną sieć. Dla sieci 156.17.4.32/28:

- Ostatni adres jest zarezerwowany: adres rozgłoszeniowy (broadcast).
 - Pakiet wysłany nas adres rozgłoszeniowy dotrze do wszystkich adresów IP z zakresu.

- * Pierwszy adres jest zarezerwowany: tzw. adres sieci.
 - * Względy historyczne (to był początkowo adres rozgłoszeniowy).

* Pozostałe 16 - 2 = 14 adresów IP może być przypisane do komputerów (kart sieciowych) w tej sieci.

Podsieci

```
156.17.4.32/28 = zbiór następujących adresów
  156.17.4.00100000 = 156.17.4.32
                                       156.17.4.32/29
  156.17.4.00100111 = 156.17.4.39
  156.17.4.00101000 = 156.17.4.40
                                       156.17.4.40/29
  156.17.4.00101111 = 156.17.4.47
```

Adres IP to za mało!

* Czy adres 156.17.4.95 jest adresem rozgłoszeniowym?

Adres IP to za mało!

- * Czy adres 156.17.4.95 jest adresem rozgłoszeniowym?
 - * Tak w sieci 156.17.4.80/28 = {156.17.4.80, ..., 156.17.4.95}
 - * Tak w sieci 156.17.4.64/27 = {156.17.4.64, ..., 156.17.4.95}
 - * Nie w sieci 156.17.4.64/26 = {156.17.4.64, ..., 156.17.4.127}

Adres IP to za mało!

- * Czy adres 156.17.4.95 jest adresem rozgłoszeniowym?
 - * Tak w sieci 156.17.4.80/28 = {156.17.4.80, ..., 156.17.4.95}
 - * Tak w sieci 156.17.4.64/27 = {156.17.4.64, ..., 156.17.4.95}
 - * Nie w sieci 156.17.4.64/26 = {156.17.4.64, ..., 156.17.4.127}

 Przy podawaniu dowolnego adresu IP powinniśmy też podać długość prefiksu określającego jego sieć, np. 156.17.4.95/26.

CIDR (3)

- * Notację CIDR rozszerzamy na wszystkie adresy IP. Przykładowo:
 - * 156.17.4.32/28 = cały zakres 16 adresów.
 - * 156.17.4.33/28 = pierwszy adres dla komp. w sieci 156.17.4.32/28.
 - * 156.17.4.34/28 = drugi adres dla komputera w sieci 156.17.4.32/28.
 - + ...
 - + 156.17.4.46/28 = ostatni adres dla komputera w sieci 156.17.4.32/28.
 - * 156.17.4.47/28 = adres rozgłoszeniowy w sieci 156.17.4.32/28.
 - Przy tej konwencji rezerwowanie pierwszego adresu na adres sieci znowu ma sens.

CIDR (3)

- Notację CIDR rozszerzamy na wszystkie adresy IP. Przykładowo:
 - * 156.17.4.32/28 = cały zakres 16 adresów.
 - * 156.17.4.33/28 = pierwszy adres dla komp. w sieci 156.17.4.32/28.
 - * 156.17.4.34/28 = drugi adres dla komputera w sieci 156.17.4.32/28.
 - + ...
 - + 156.17.4.46/28 = ostatni adres dla komputera w sieci 156.17.4.32/28.
 - * 156.17.4.47/28 = adres rozgłoszeniowy w sieci 156.17.4.32/28.
 - Przy tej konwencji rezerwowanie pierwszego adresu na adres sieci znowu ma sens.
- Długość prefiksu nazywamy maską (pod)sieci.
 - * Czasem zapisywany w postaci bitowej /28 = /255.255.255.240 (28 jedynek).
 - * Aby uzyskać adres sieci robimy logiczny AND adresu IP z maską sieci.

Klasy adresów

- * Jeśli nie podamy maski sieci, niektóre starsze polecenia (np. ifconfig) wydedukują ją z adresu IP.
 - * ifconfig eth0 10.0.0.1 = ifconfig eth0 10.0.0.1 netmask 255.0.0.0

- Przyczyny historyczne (klasy adresów IP).
 - Adres IP zaczyna się od 0 → maska sieci = /8 (klasa A).
 - * Adres IP zaczyna się od 10 → maska sieci = /16 (klasa B).
 - + Adres IP zaczyna się od 110 → maska sieci = /24 (klasa C).

Pętla lokalna = sieć 127.0.0.0/8

- Interfejs lo (loopback)
- Łącząc się z dowolnym adresem z tej sieci (zazwyczaj z 127.0.0.1), łączymy się z lokalnym komputerem.
- Testowanie aplikacji sieciowych bez połączenia z siecią.

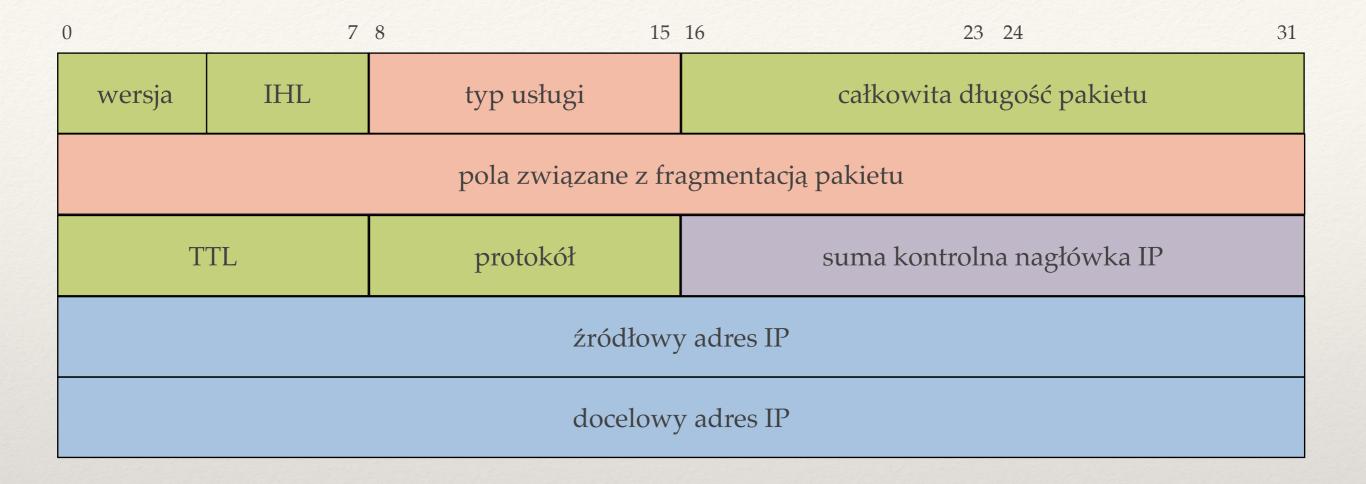
Przykład konfiguracji

```
eth0: <BROADCAST,MULTICAST> mtu 1500 state UP
    link/ether d8:cb:8a:34:a4:66 brd ff:ff:ff:ff:ff
inet 156.17.4.30/24 brd 156.17.4.255 scope global eth0
```

tun0 <POINTOPOINT,MULTICAST,NOARP> mtu 1500 state UNKNOWN
link/none
inet 172.28.0.1/16 brd 172.28.255.255 scope global tun0

Routing pakietów IP

Nagłówek pakietu IP



- * 4 x IHL = długość nagłówka w bajtach.
- * Protokół = datagram jakiego protokołu przechowywany jest w danych pakietu (np. 1 = ICMP, 6 = TCP, 17 = UDP).
- * TTL = czas życia pakietu.

Przetwarzanie pakietu w routerze

1. Obliczenie portu wyjściowego (wyjściowej "karty sieciowej"):

 na podstawie adresu docelowego pakietu i posiadanej tablicy routingu.

2. Aktualizacja nagłówka:

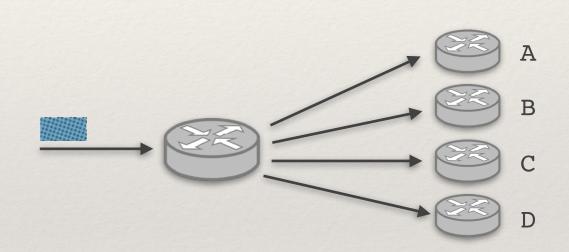
- * zmniejszenie TTL o 1; jeśli TTL = 0, to pakiet wyrzucany;
- ponowne wyliczenie sumy kontrolnej pakietu.

3. Przekazanie pakietu do kolejki wyjściowej.

Tablice routingu

* Tablica routingu zawiera reguły typu "jeśli adres docelowy pakietu zaczyna się od prefiksu *A*, to wyślij pakiet do X".

prefiks CIDR	akcja	
10.20.30.0/24	do routera A	
8.0.0.0/8	do routera B	
9.9.9.0/24	do routera C	
156.17.0.0/16	do routera C	
156.18.0.0/16	do routera D	

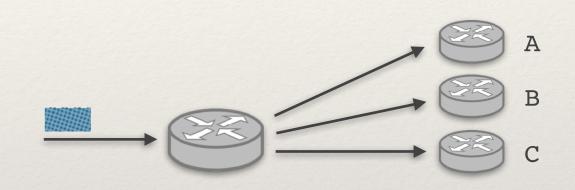


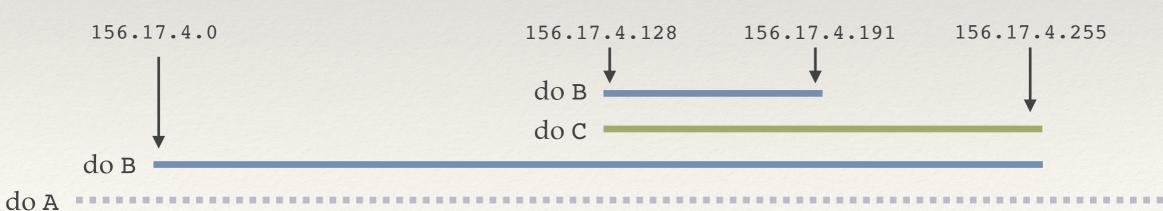
* Pakiet niepasujący do żadnej reguły jest odrzucany.

Reguła najdłuższego pasującego prefiksu

- * Jeśli więcej niż jedna reguła pasuje, wybierana jest ta, która jest najdłuższym prefiksem (najbardziej "konkretna reguła").
- * 0.0.0.0/0 = regula (trasa) domyślna.

prefiks CIDR	akcja	
0.0.0.0/0	do routera A	
156.17.4.0/24	do routera B	
156.17.4.128/25	do routera C	
156.17.4.128/26	do routera B	





Równoważne tablice routingu



Następny krok

- Akcja z tablicy routingu = wysłanie pakietu do
 - osiągalnej bezpośrednio przez interfejs sieci S
 (jeśli adres docelowy jest w S)
 - osiągalnego bezpośrednio przez interfejs routera X (w przeciwnym przypadku)

* **Bezpośrednio** = warstwa sieciowa nie bierze udziału w przesyłaniu, choć pakiet może być przesyłany między wieloma urządzeniami.

Przykładowa tablica routingu w komputerze

\$> ip route

156.17.4.0/24

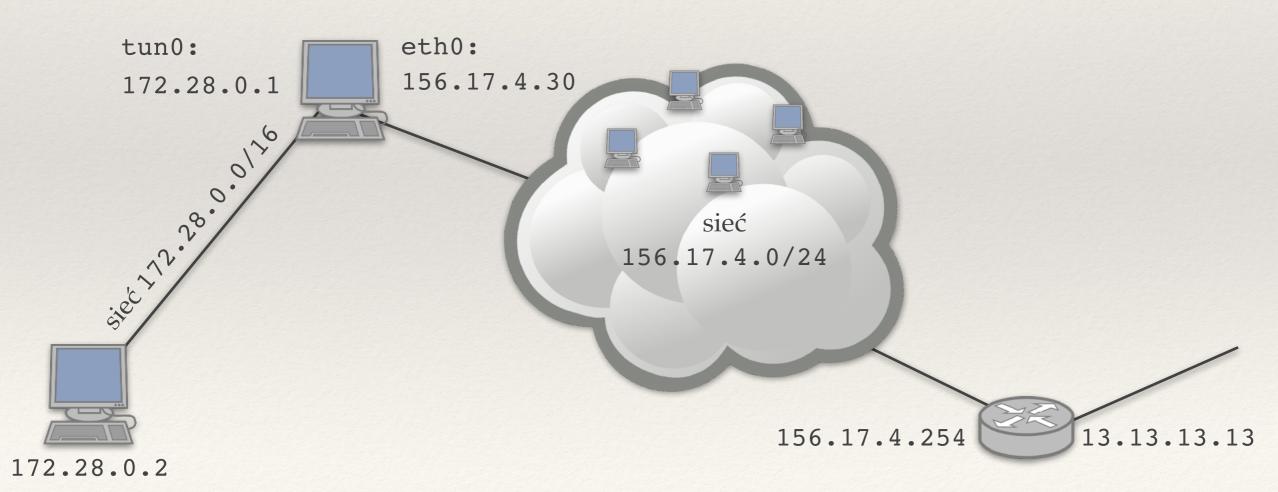
172.28.0.0/16

0.0.0.0/0

dev eth0 src 156.17.4.30

dev tun0 src 172.28.0.1

via 156.17.4.254 dev eth0



Przykładowa tablica routingu w komputerze

Regula dodana w momencie przypisywania adresu IP 156.17.4.30/24

\$> ip route

156.17.4.0/24

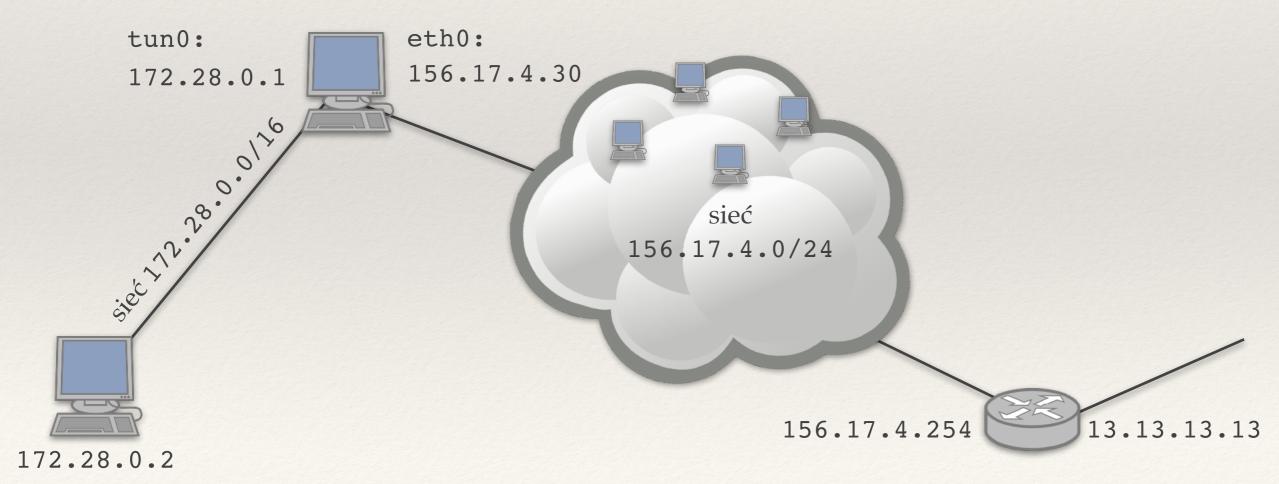
172.28.0.0/16

0.0.0.0/0

dev eth0 src 156.17.4.30

dev tun0 src 172.28.0.1

via 156.17.4.254 dev eth0



ICMP

ICMP (Internet Control Message Protocol)

Protokół pomocniczy warstwy trzeciej.

 Pakiety ICMP są enkapsulowane w pakietach IP (stanowią pole danych w pakiecie IP).

nagłówek	nagłówek	dane
IP	ICMP	ICMP

Nagłówek ICMP (bajty 5-8 mogą nie występować):

0 7	8 15	6 23 24	31
typ	podtyp (kod)	suma kontr	olna
identyfikator		numer sekwencyjny	

Ping

- * Wysyła żądanie ICMP o typie 8 (echo request).
 - * W danych ICMP jest m.in. znacznik czasowy.
- * Odbiorca odsyła komunikat ICMP o typie 0 (echo reply).
 - * W danych ICMP są dokładnie te same pola co w żądaniu.
 - Na tej podstawie można wyznaczyć bieżący RTT.

```
PING whitehouse.gov (104.89.18.154): 56 data bytes
64 bytes from 104.89.18.154: icmp_seq=0 ttl=58 time=65.080 ms
64 bytes from 104.89.18.154: icmp_seq=1 ttl=58 time=67.033 ms
64 bytes from 104.89.18.154: icmp_seq=2 ttl=58 time=68.533 ms
```

Traceroute (1)

* Pakiet IP z startowym TTL = j, zostaje odrzucony przez j-ty router na trasie do celu. Router ten odeśle komunikat ICMP $time\ exceeded$ (typ 11, podtyp 0).

- * traceroute wyświetla ścieżkę do docelowego adresu IP:
 - * Pakiety mają coraz większe TTL.
 - Wysyłamy ICMP echo request → komputer docelowy odpowie komunikatem ICMP echo reply.
 - Albo pakiet UDP do rzadko używanego portu → komputer docelowy odpowie komunikatem ICMP port unreachable.

Traceroute (2)

```
traceroute to www.ii.uni.wroc.pl (156.17.4.3), 64 hops max, 52 byte packets
    livebox (192.168.1.1) 3.151 ms
 1
   wro-bng2.tpnet.pl (80.50.18.74) 31.965 ms
 2
 3
   wro-r2.tpnet.pl (80.50.122.73) 31.870 ms
 4
    lodz-ar3.tpnet.pl (213.25.5.206) 62.835 ms
 5
    z-tpnetu.lodz-gw.rtr.pionier.gov.pl (80.50.231.26) 37.103 ms
    lodz-gw2.z-lodz-gw.rtr.pionier.gov.pl (212.191.126.77) 37.606 ms
 6
 7
    z-lodz-gw.wroclaw.10gb.rtr.pionier.gov.pl (212.191.225.34) 44.687 ms
    rolnik-karkonosz.wask.wroc.pl (156.17.254.112) 46.707 ms
 8
 9
    archi-rolnik.wask.wroc.pl (156.17.254.108) 47.936 ms
10
    matchem-archi.wask.wroc.pl (156.17.254.142) 47.986 ms
    gwuwrmatchem.uni.wroc.pl (156.17.252.33) 49.342 ms
11
   www.ii.uni.wroc.pl (156.17.4.3) 48.511 ms
12
```

Programowanie gniazd (wstęp)

Gniazda

Gniazda = interfejs programistyczny do nadawania i odbierania pakietów

Umożliwiają podawanie danych do umieszczenia w datagramach UDP lub segmentach TCP.



dostęp do niektórych pól za pomocą funkcji gniazd

* Gniazda surowe: umożliwiają podawanie danych do umieszczenia bezpośrednio w danych pakietu IP.

nagłówek IP dane zapisywane do gniazda

Kolejność bajtów w liczbach całkowitych

- Liczba całkowita (np 0x4A3B2C1D) jest przechowywana inaczej na różnych architekturach. Przykładowo:
 - + PowerPC: 0x4A, 0x3B, 0x2C, 0x1D (big endian).
 - + Intel x86: 0x1D, 0x2C, 0x3B, 0x4A (little endian).

* W nagłówkach pakietów są liczby, protokoły wymagają "sieciowej kolejności bajtów" (*big endian*).

Do konwersji służą funkcje htons, htonl, ntohs, ntohl.

Sprawdzanie błędów

- * Funkcje dotyczące gniazd często zwracają błędy.
- Zwrócona wartość mniejsza od 0 zazwyczaj oznacza błąd.
- Nod błędu: errno → jako komunikat: strerror(errno).

Tworzenie gniazda surowego

```
#include <arpa/inet.h>
int sockfd = socket(AF INET, SOCK RAW, IPPROTO ICMP);
```

- * Gniazdo surowe otrzymuje kopię wszystkich pakietów danego protokołu (w tym przypadku ICMP).
- sockfd jest deskryptorem gniazda podobnym do deskryptora pliku czy potoku.

Programowanie gniazd (odbieranie pakietów)

Odbieranie pakietu z gniazda

recvfrom odbiera kolejny pakiet z kolejki związanej z gniazdem.

```
struct sockaddr in sender;
                      sender_len = sizeof(sender);
socklen t
                      buffer [IP MAXPACKET];
u int8 t
ssize t packet len = recvfrom (
    sockfd,
    buffer,
                                        pakiet jako ciąg bajtów
    IP MAXPACKET,
    0,
    (struct sockaddr*)&sender,
                                      — informacje o nadawcy
    &sender len
```

Internetowa struktura adresowa

```
struct sockaddr_in {
  sa_family_t sin_family;
  in_port_t sin port;
  struct in addr sin addr;
  // tutaj zera
char sender_ip_str[20];
inet_ntop (
 AF INET,
  &(sender.sin addr),
  sender_ip_str,
  sizeof(sender_ip_str)
```

zdefiniowana w netinet/in.h

zamienia strukturę adresową w **sender** na napis z adresem IP

Odczyt nagłówka IP

```
struct ip
                                   zdefiniowana w netinet/ip.h
  unsigned int ip_hl:4;
  u_int32_t saddr;
  u_int32_t daddr;
};
struct ip* ip_header = (struct ip*) buffer;
u_int8_t* icmp packet = buffer + 4 * ip_header->ip hl;
                       buffer
                       icmp packet
  nagłówek
               nagłówek
                            dane ICMP
                ICMP
     \mathsf{TP}
```

Odczyt nagłówka ICMP

```
struct icmp
                            zdefiniowana w netinet/ip icmp.h
 u_int8_t icmp_type;
 u_int8_t icmp code;
};
struct ip* ip header = (struct ip*) buffer;
u_int8_t* icmp_packet = buffer + 4 * ip header->ip hl;
struct icmp* icmp header = (struct icmp*) icmp packet
                     buffer
                     icmp_packet
  nagłówek
              nagłówek
                           dane ICMP
               ICMP
     TP
```

Kod odbierający pakiety

```
int sockfd = socket(AF INET, SOCK RAW, IPPROTO ICMP);
for (;;) {
                                                   Brak obsługi błędów!
 struct sockaddr in sender;
              sender len = sizeof(sender);
 socklen t
 u_int8_t
            buffer[IP MAXPACKET];
 ssize t packet len = recvfrom (sockfd, buffer, IP MAXPACKET, 0,
                         (struct sockaddr*)&sender, &sender len);
 char ip_str[20]; // sender IP
  inet_ntop (AF_INET, &(sender.sin_addr), ip_str, sizeof(ip_str));
 printf ("IP packet with ICMP content from: %s\n", ip str);
 struct ip* ip header = (struct ip*) buffer;
 ssize_t ip header len = 4 * ip header->ip hl;
 // IP header = buffer [0, ip header len-1]
                                                          demonstracja
 // IP data = buffer [ip_header_len, packet_len-1]
```

Tryb nieblokujący

* Funkcja recvfrom():

- * Standardowe wywołanie blokuje aż w gnieździe będzie pakiet.
- * Zazwyczaj nie chcemy czekać więcej niż *x* sekund.

* Tryb nieblokujący:

- + Czwarty parametr recvfrom() równy MSG_DONTWAIT.
- → Jeśli w gnieździe nie ma pakietów, to recvfrom() kończy działanie zwracając -1 zaś errno = EWOULDBLOCK.

Tryb nieblokujący

* Funkcja recvfrom():

- * Standardowe wywołanie blokuje aż w gnieździe będzie pakiet.
- * Zazwyczaj nie chcemy czekać więcej niż *x* sekund.

* Tryb nieblokujący:

- + Czwarty parametr recvfrom() równy MSG_DONTWAIT.
- → Jeśli w gnieździe nie ma pakietów, to recvfrom() kończy działanie zwracając -1 zaś errno = EWOULDBLOCK.

* Aktywne czekanie:

- * Wywołujemy w pętli cały czas recvfrom(sockfd,_,_,MSG_DONTWAIT,_,_).
- Sprawdzamy, ile czasu upłynęło od ostatniego odczytu.
- * Wada: 100% zużycie procesora!

Czekanie maksymalnie x milisekund na pakiet w gnieździe sockfd.

Czekanie maksymalnie x milisekund na pakiet w gnieździe sockfd.

```
struct pollfd ps;
  ps.fd = sockfd;
  ps.events = POLLIN;
  ps.revents = 0;
int ready = poll (&ps, 1, x);
```

nieblokującym.

Czekanie maksymalnie x milisekund na pakiet w gnieździe sockfd.

```
struct pollfd ps;
  ps.fd = sockfd;
  ps.events = POLLIN;
  ps.revents = 0;
int ready = poll (&ps, 1, x);
* ready = 0 \rightarrow nastąpił timeout (po x milisekundach).

    * ready < 0 → wystąpił błąd (zazwyczaj przerwanie sygnałem)
</p>
* ready > 0 → ready obserwowanych deskryptorów "gotowych do odczytu".
   * Trzeba sprawdzić, czy ps.revents == POLLIN!
      * np. ps.revents = POLLHUP oznacza, np. że druga strona zamknęła połączenie.
     Pierwsze wywołanie recvfrom (sockfd, ...) nie zablokuje.
```

♦ W gnieździe sockfd może być więcej niż jeden pakiet → można je odczytać w trybie

nieblokującym.

Czekanie maksymalnie x milisekund na pakiet w gnieździe sockfd.

```
struct pollfd ps;
  ps.fd = sockfd;
  ps.events = POLLIN;
  ps.revents = 0;
int ready = poll (&ps, 1, x);
                                                                Obserwowaliśmy 1,
* ready = 0 \rightarrow nastąpił timeout (po x milisekundach).
                                                                   wiec ready = 1
* ready < 0 → wystąpił błąd (zazwyczaj przerwanie sygnałem)</p>
* ready > 0 → ready obserwowanych deskryptorów "gotowych do odczytu".
   * Trzeba sprawdzić, czy ps.revents == POLLIN!
      * np. ps.revents = POLLHUP oznacza, np. że druga strona zamknęła połączenie.
    Pierwsze wywołanie recvfrom (sockfd, ...) nie zablokuje.
```

♦ W gnieździe sockfd może być więcej niż jeden pakiet → można je odczytać w trybie

Programowanie gniazd (wysyłanie pakietów)

Tworzenie danych do wysyłki

Konstruujemy komunikat ICMP do wysłania. W przypadku ICMP echo request wystarczy sam nagłówek.

Funkcja obliczająca 16-bitową sumę kontrolną w kodzie uzupełnień do jedności jest na stronie wykładu

Adresowanie

Wpisujemy adres odbiorcy do struktury adresowej:

```
struct sockaddr_in recipient;
bzero (&recipient, sizeof(recipient));
recipient.sin_family = AF_INET;
inet_pton(AF_INET, "adres_ip", &recipient.sin_addr);
```

Opcje gniazda

Pole TTL jest w nagłówku IP → brak bezpośredniego dostępu. Zmiana wywołaniem:

```
ttl = 42;
setsockopt (sockfd, IPPROTO_IP, IP_TTL, &ttl, sizeof(int));
```

Wysyłanie pakietu przez gniazdo

```
ssize_t bytes_sent = sendto (
   sockfd,
   &header,
   sizeof(header),
   0,
   (struct sockaddr*)&recipient,
   sizeof(recipient)
);
```

Lektura dodatkowa

- Kurose & Ross: rozdział 4.
- * Tanenbaum: rozdział 5.
- * Stevens: rozdział 25.
- Dokumentacja IP i ICMP:
 - https://web.archive.org/web/20220412004810/http://
 www.networksorcery.com/enp/protocol/ip.htm
 - https://web.archive.org/web/20220410210745/http://
 www.networksorcery.com/enp/protocol/icmp.htm

Zagadnienia

- Z czego wynika hierarchia adresów IP? Jaki ma wpływ na konstrukcję tablic routingu?
- Notacja CIDR.
- Co to jest adres rozgłoszeniowy?
- Co to jest maska podsieci
- * Opisz sieci IP klasy A, B i C.
- Co to jest petla lokalna (loopback)?
- Do czego służy pole TTL w pakiecie IP? Do czego służy pole protokół?
- Jakie reguły zawierają tablice routingu?
- Na czym polega reguła najdłuższego pasującego prefiksu?
- Co to jest trasa domyślna?
- Do czego służy protokół ICMP? Jakie znasz typy komunikatów ICMP?
- Jak działa polecenie ping?
- Jak działa polecenie traceroute?
- * Dlaczego do tworzenia gniazd surowych wymagane są uprawnienia administratora?
- Co to jest sieciowa kolejność bajtów?
- Co robia funkcje socket(), recvfrom() i sendto()?
- * Jakie informacje zawiera struktura adresowa sockaddr_in?
- Co to jest tryb blokujący i nieblokujący? Co to jest aktywne czekanie?
- * Jakie jest działanie funkcji select()?