# Transport

## część 3: kontrola przeciążenia

Sieci komputerowe

Wykład 8

*Marcin Bieńkowski*

# Protokoły w Internecie

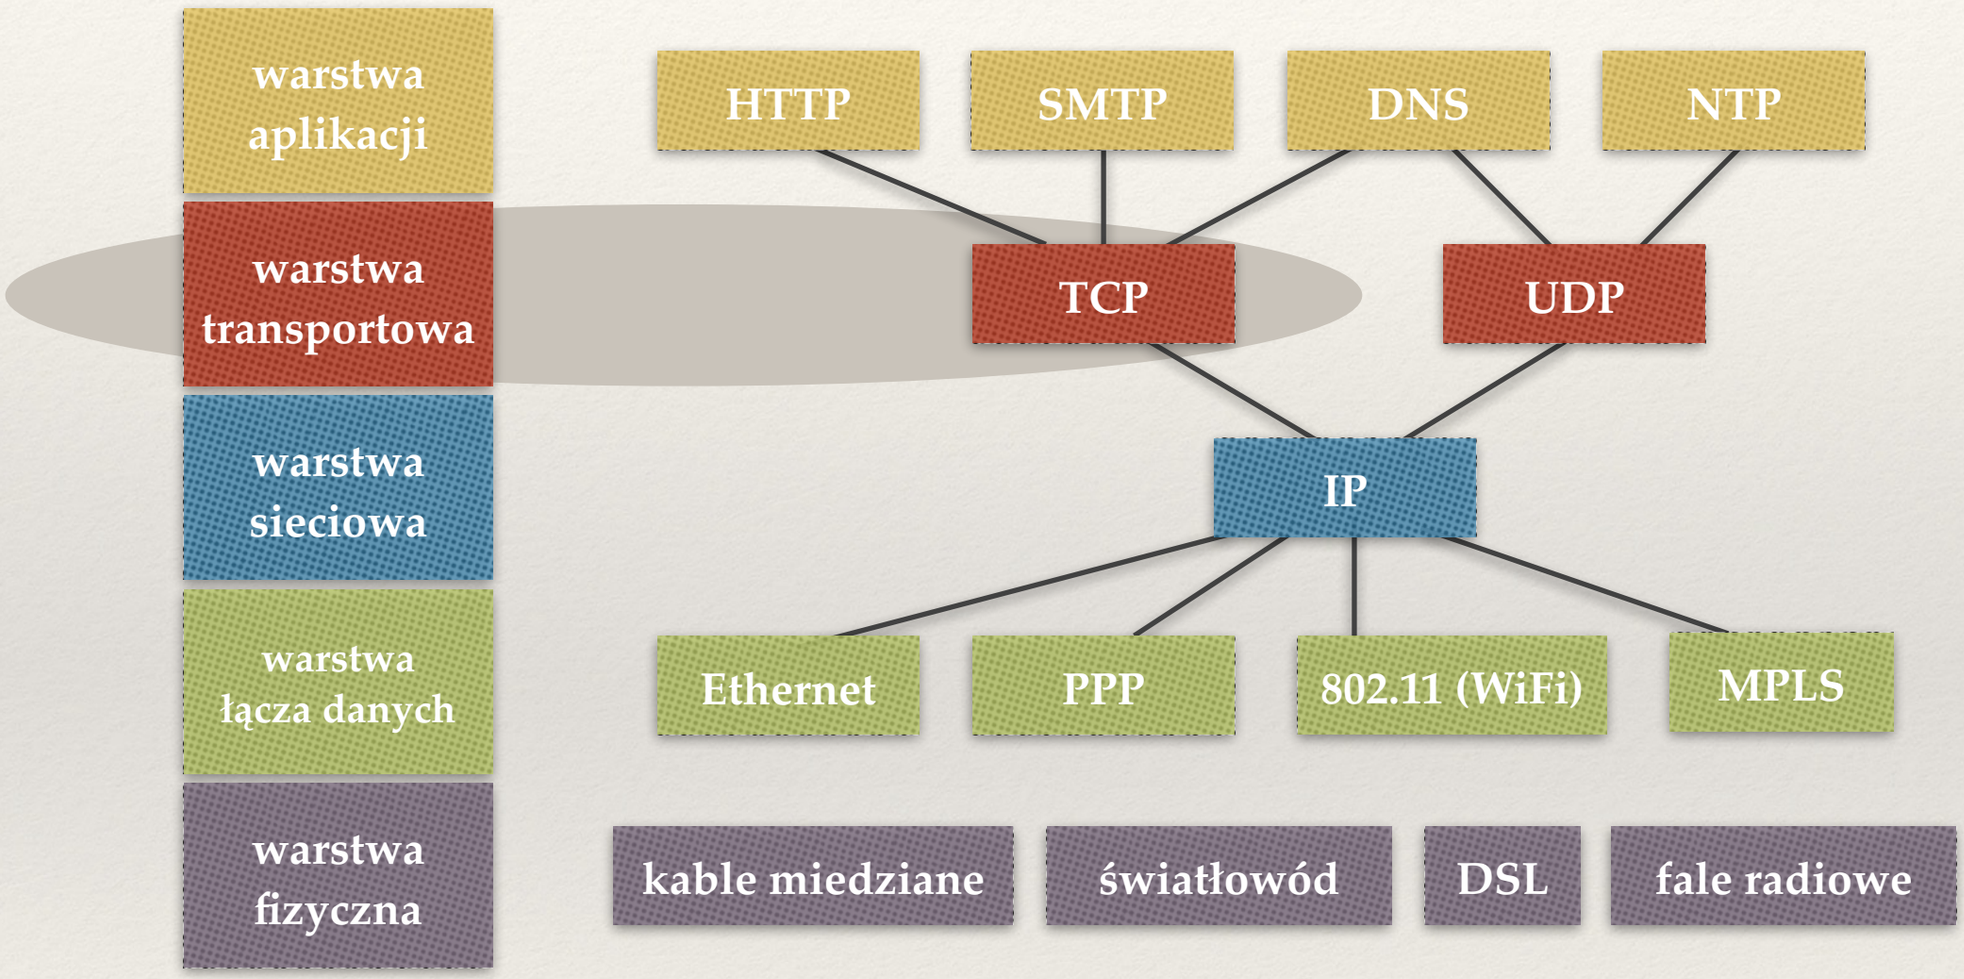

# Podsumowanie mechanizmów warstwy transportowej

# Warstwa sieci = zawodna usługa przesyłania pakietów

- Tylko zasada dołożenia wszelkich starań (*best effort*)

- **Pakiety mogą zostać:**
  - uszkodzone,
  - zgubione,
  - opóźnione,
  - zamienione (kolejność),
  - zduplikowane (przez wyższe lub niższe warstwy).

# Podstawowe mechanizmy w warstwie transportowej

- **Segmentacja:** dzielimy przesyłany strumień danych na kawałki; **dla uproszczenia będziemy wszystko liczyć w segmentach**.

- **Potwierdzenia (ACK):** małe pakiety kontrolne potwierdzające otrzymanie danego segmentu.

- **Timeout (przekroczenie czasu oczekiwania):** jeśli nie otrzymamy potwierdzenia przez pewien czas (typowy dla łącza, np. 2 * RTT).

- **Retransmisje:** ponowne wysłanie danego segmentu w przypadku przekroczenia czasu oczekiwania.

# Co umiemy już zapewniać?

- **Niezawodny transport**
  - Mechanizmy ARQ (Automatic Repeat reQuest) = wysyłanie do skutku

- **Kontrola przepływu**
  - Nadawca powinien dostosowywać prędkość transmisji do szybkości z jaką odbiorca może przetwarzać dane.

- **Jak?**
  - Najczęściej: okno przesuwne + potwierdzenia skumulowane.

# Przypomnienie: przesuwne okno nadawcy


**Akcje:**

- Otrzymanie ACK → sprawdzamy, czy możemy przesunąć okno.
- Przesunięcie okna → wysyłamy dodatkowe segmenty.
- Timeout dla (niepotwierdzonego) segmentu → wysyłamy go ponownie.

# Przypomnienie: okno odbiorcy, potwierdzanie skumulowane

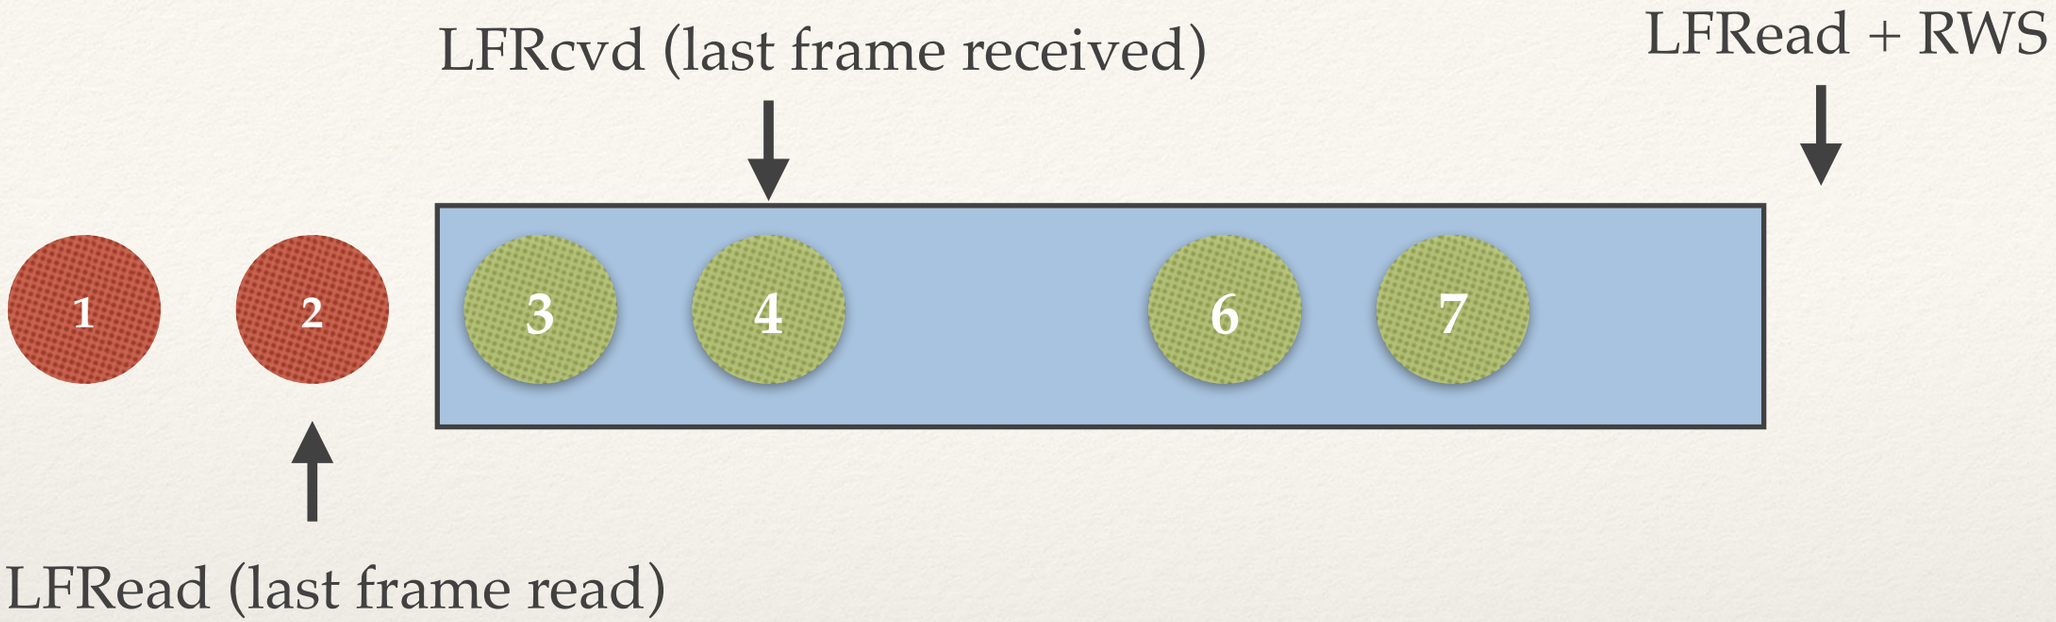


odebrane, potwierdzone, przeczytane przez aplikację

odebrane (i potwierdzone) ale nieprzeczytane przez aplikację

- **Wysyłanie ACK:**
  - Wysyłamy tylko jeśli otrzymamy segment S ≤ LFRead + RWS
  - W razie potrzeby aktualizujemy LFRcvd (przesuwamy okno w prawo) a następnie wysyłamy **ACK dla LFRcvd**.

# Przypomnienie: oferowane okno

**Odbiorca:**

- Oferowane okno = wolne miejsce w buforze
- Oferowane okno wysyłane nadawcy (zazwyczaj razem z ACK).
- Np.: pakiety potwierdzane, ale aplikacja wolno czyta → oferowane okno jest małe.


**Nadawca:**

- Zmienia SWS (rozmiar swojego okna) na rozmiar oferowanego okna.
- W efekcie zazwyczaj nie wysyła danych, na które odbiorca nie ma miejsca

# SWS a prędkość transmisji

**SWS = 1:**

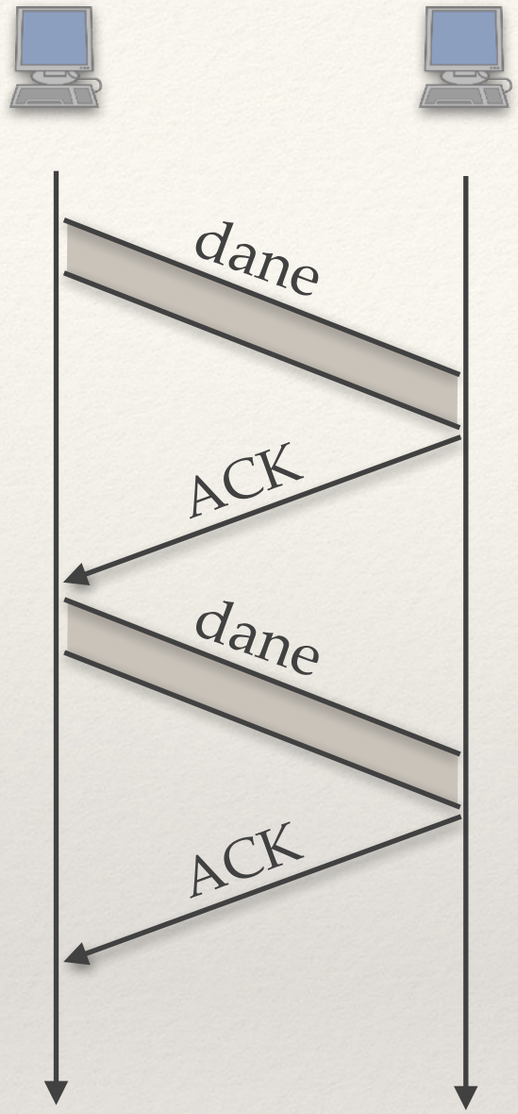


**większe SWS:**

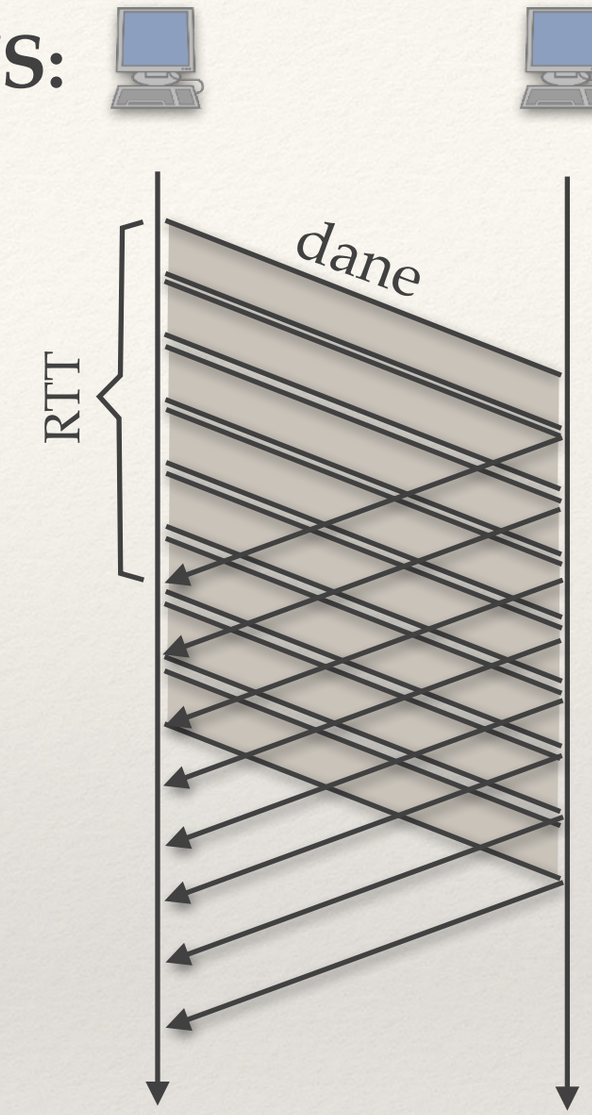


- Dane wysyłane są ze średnią prędkością SWS / RTT.
- Okno mniejsze od BDP = przepustowość * RTT
  → nadawca nie jest w stanie wykorzystać całego łącza.

# Problem przeciążenia

# Statystyczny multipleksing

Różne strumienie danych przesyłane tym samym łączem.

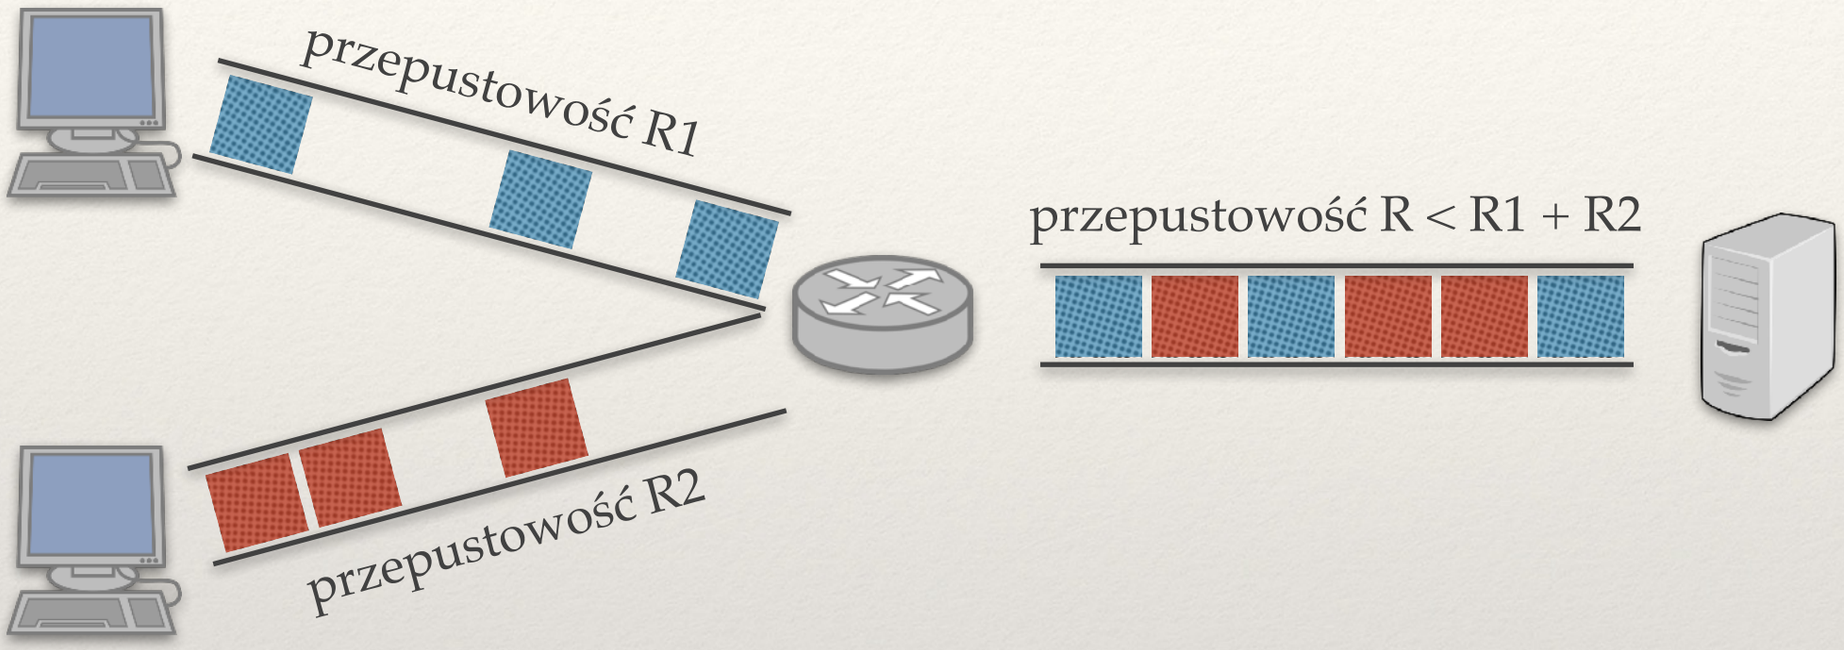


Założenie: różne komputery wykorzystują łącze w innych momentach
→ lepsze wykorzystanie łącza.

# Bufory

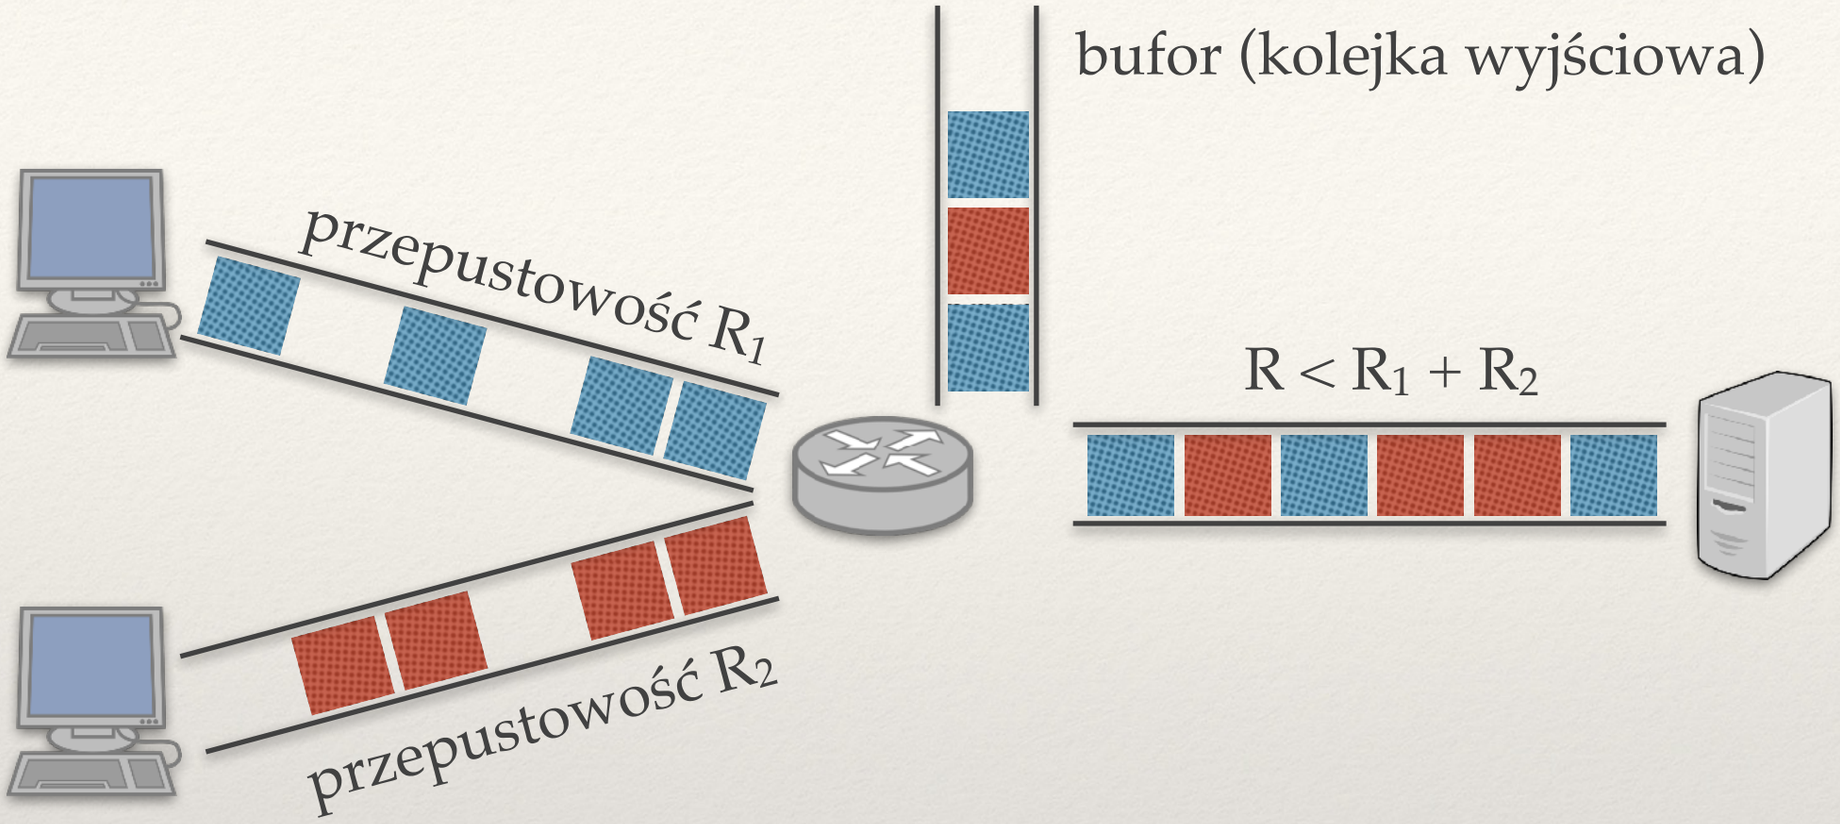


Bufory przy łączach wyjściowych:

- Pomagają przy **przejściowym** nadmiarze pakietów.
- Jeśli bufor się przepełni (**przeciążenie**) → pakiety są odrzucane.
- Dlaczego nie zrobić większych buforów?

# Zwiększyć bufory?

- Rozmiar bufora na trasie nie wpływa na przepustowość.
  - Przepustowość na trasie wynika z najwolniejszego łącza.

# Zwiększyć bufory?

- Rozmiar bufora na trasie nie wpływa na przepustowość.
  - Przepustowość na trasie wynika z najwolniejszego łącza.

- Jeśli daną trasą będziemy cały czas przesyłać więcej niż jej przepustowość, to bufory będą całkowicie zapełnione.
  - większe bufory → większe kolejki
  - większe kolejki → większe opóźnienie!

# Zwiększyć bufory?

- Rozmiar bufora na trasie nie wpływa na przepustowość.
  - Przepustowość na trasie wynika z najwolniejszego łącza.

- Jeśli daną trasą będziemy cały czas przesyłać więcej niż jej przepustowość, to bufory będą całkowicie zapełnione.
  - większe bufory → większe kolejki
  - większe kolejki → większe opóźnienie!

- Przy dużych buforach pakiety są tak opóźniane, że TCP zaczyna wysyłać je ponownie → jeszcze bardziej zwiększa przeciążenie!

# Rozmiar kolejki

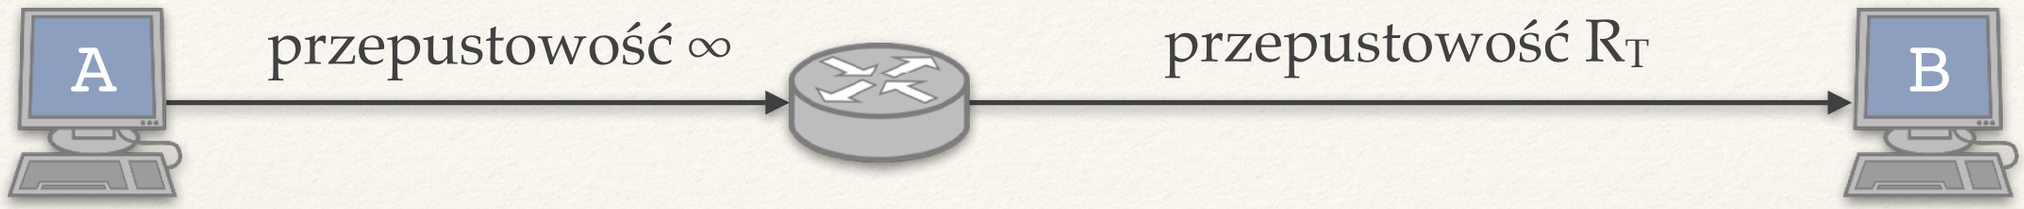


- Załóżmy, że pakiety wysyłane są od A do B losowo, ze **średnią** prędkością R.
- Matematyczna teoria kolejek → wykres rozmiaru kolejki.
- Opóźnienie jest liniową funkcją rozmiaru kolejki.

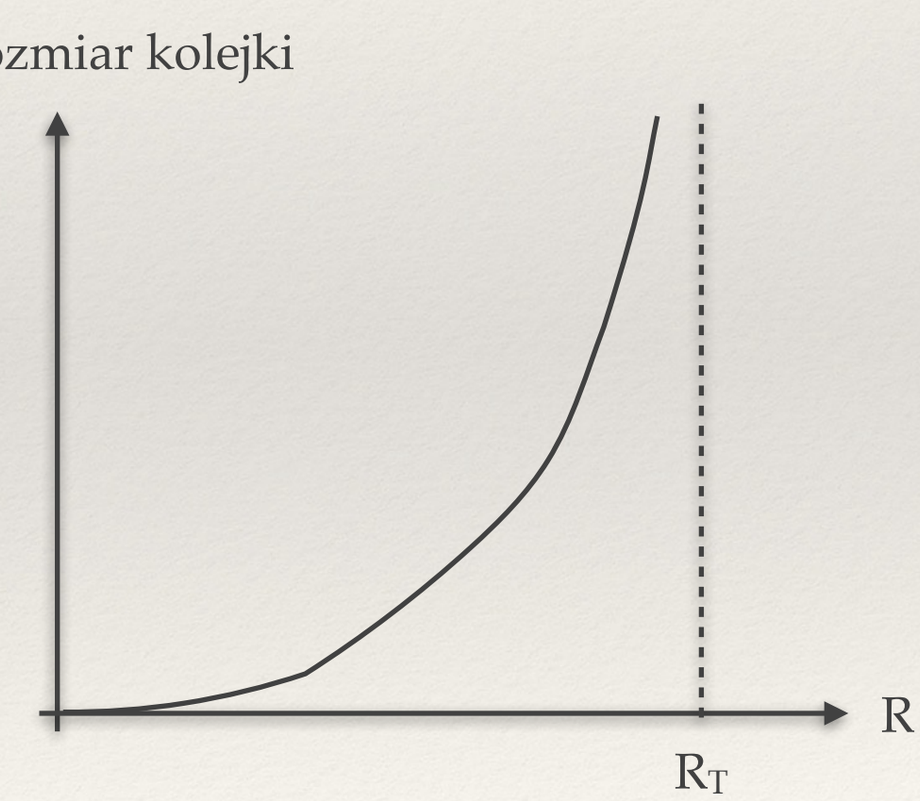

# Opóźnienie i faktyczna przepustowość (1)

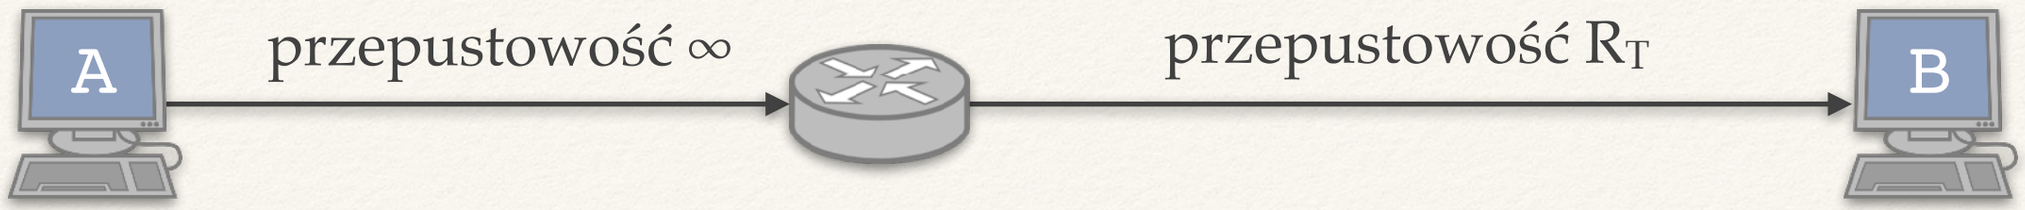


- Potrzebujemy sposobu na spowolnienie strumienia danych.

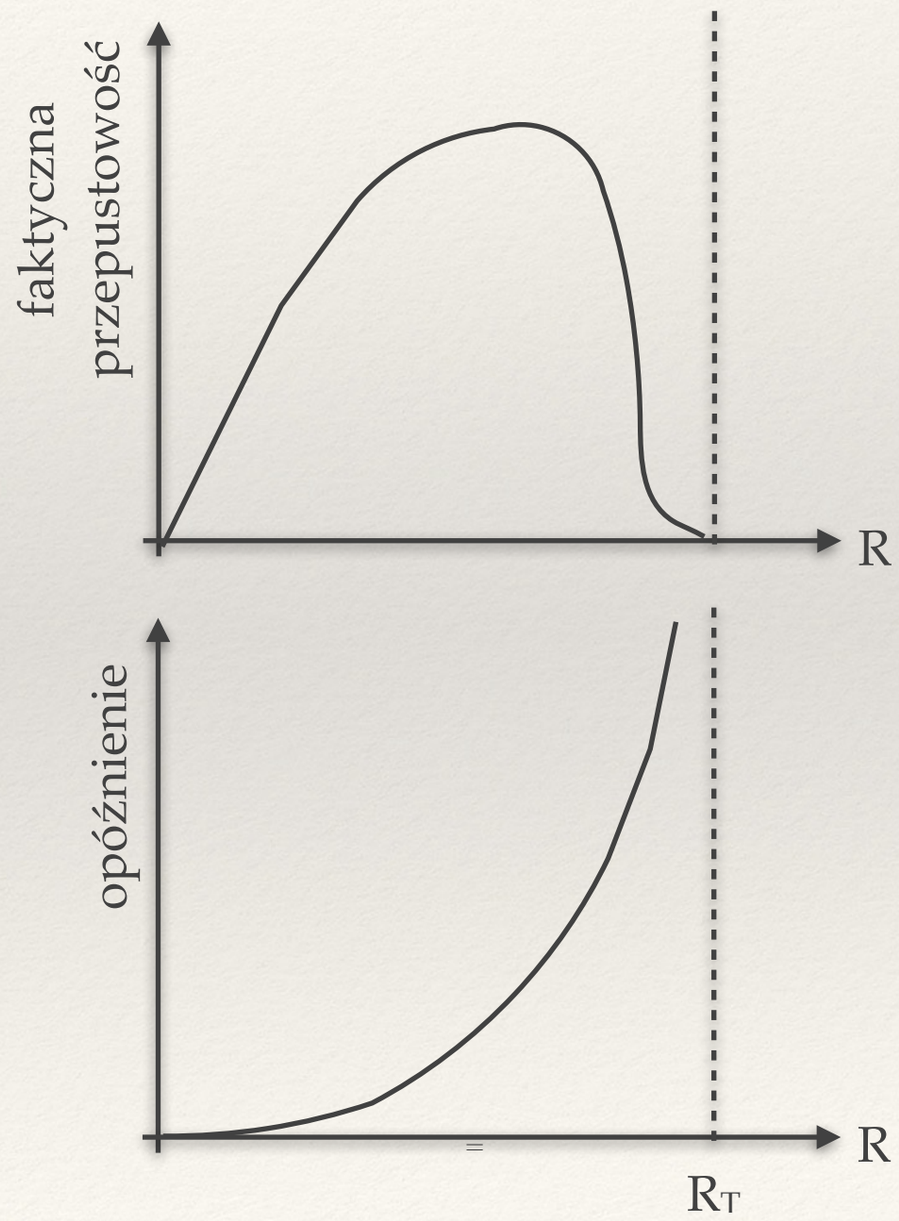


- W przeciwnym przypadku:
  - bardzo duże opóźnienia,
  - bardzo małą faktyczną przepustowość (dużo duplikatów).

# Opóźnienie i faktyczna przepustowość (2)

**Stan bliski przeciążenia jest dobry.**

- Pełne kolejki
  → większe opóźnienia.
- Puste kolejki
  → moglibyśmy nadawać szybciej!
- Chcemy mieć mechanizm, który będzie utrzymywać obciążenie w okolicach optymalnego punktu.

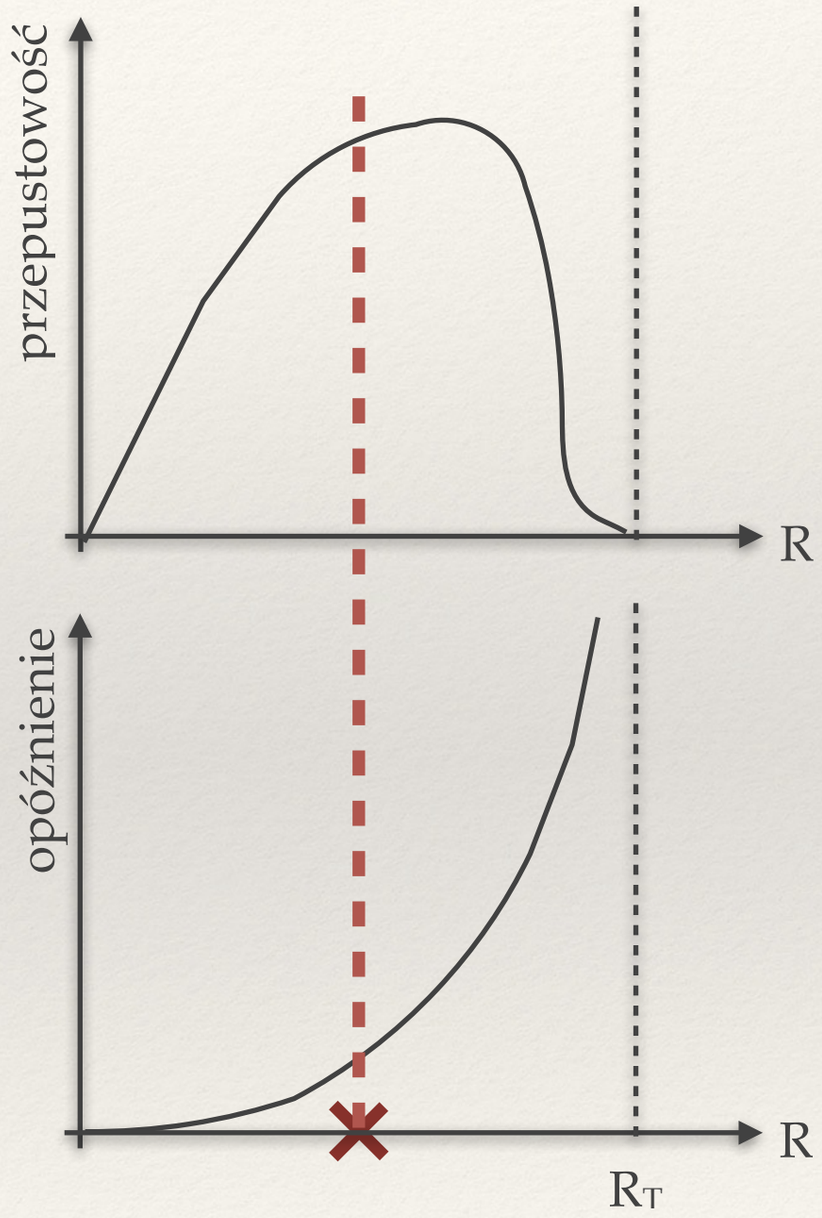

# Cele kontroli przeciążenia

- **Wysokie wykorzystanie łączy.**
  - Wykorzystane łącza → szybkie przesyłanie danych.
  - Małe opóźnienia
- **Sprawiedliwy podział łącza (*fairness*).**
  - Co to znaczy?
- **Dodatkowe cele**
  - Rozproszony algorytm.
  - Szybko reaguje na zmieniające się warunki.

# Sprawiedliwy podział łącza

# Sprawiedliwy podział łącza: przykład 1

- Każde łącze ma przepustowość 12 Mbit/s.
- Każdy komputer chce wysyłać do serwera jak najszybciej.

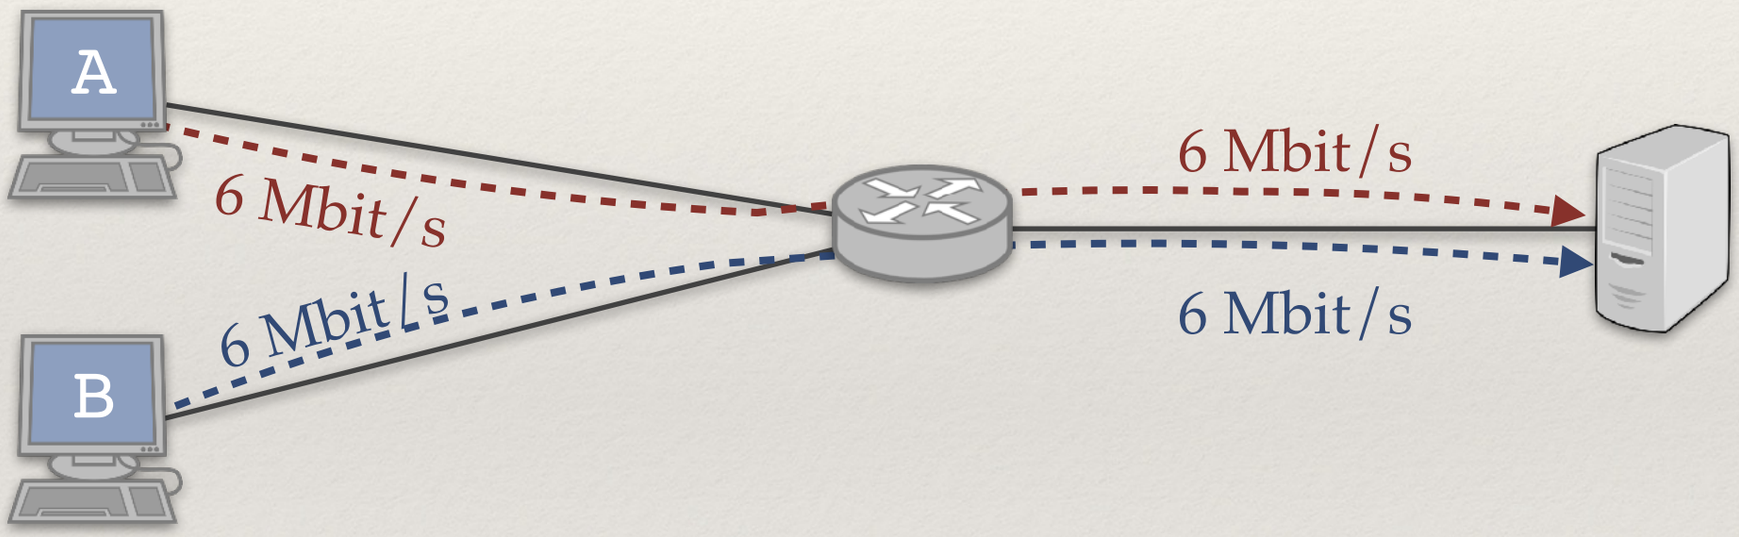

# Sprawiedliwy podział łącza: przykład 2

- Każde łącze ma przepustowość 12 Mbit/s.
- Każdy komputer chce wysyłać do serwera jak najszybciej.

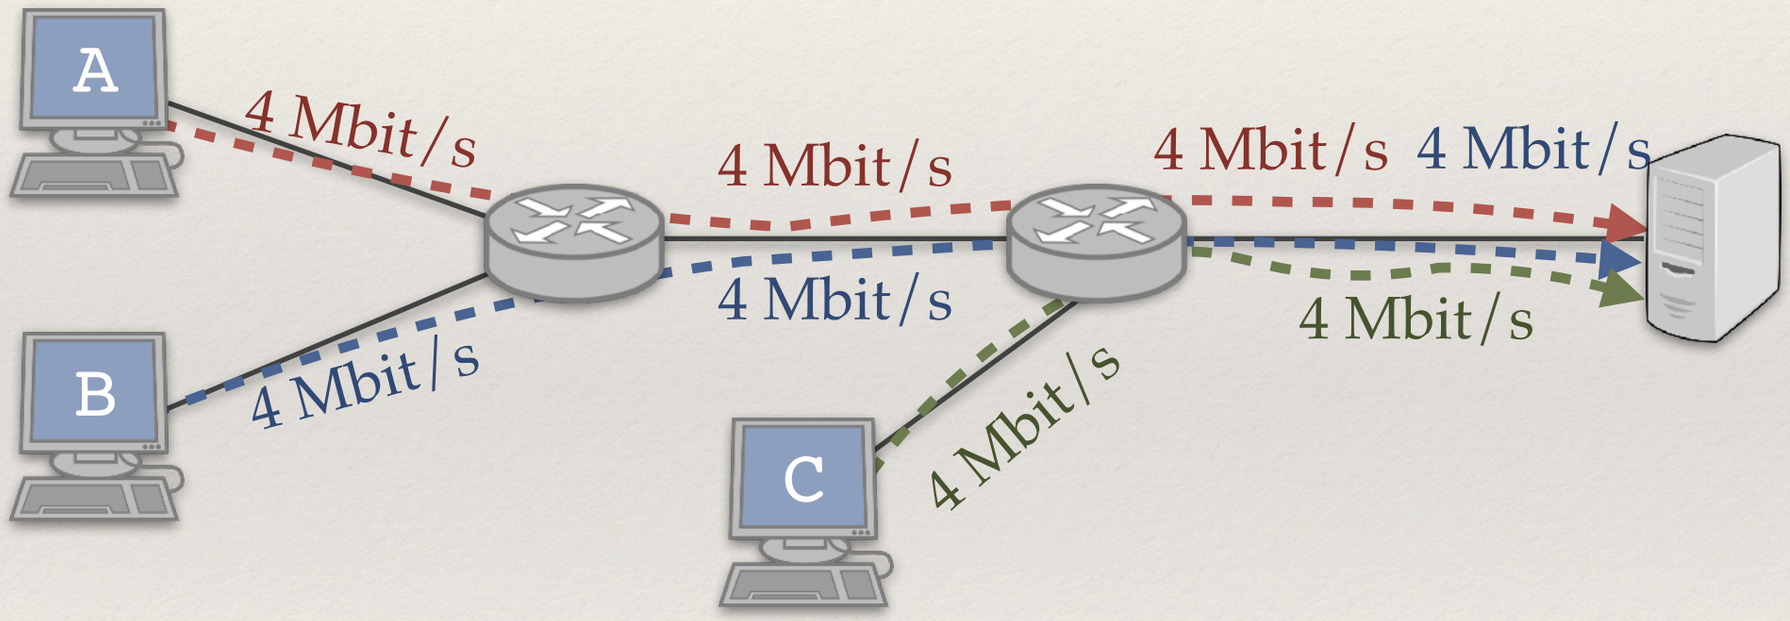

# Sprawiedliwy podział łącza: przykład 3

- Każde łącze ma przepustowość 12 Mbit/s, poza łączem między B a routerem, które ma przepustowość 2 Mbit/s.
- Każdy komputer chce wysyłać do serwera jak najszybciej.

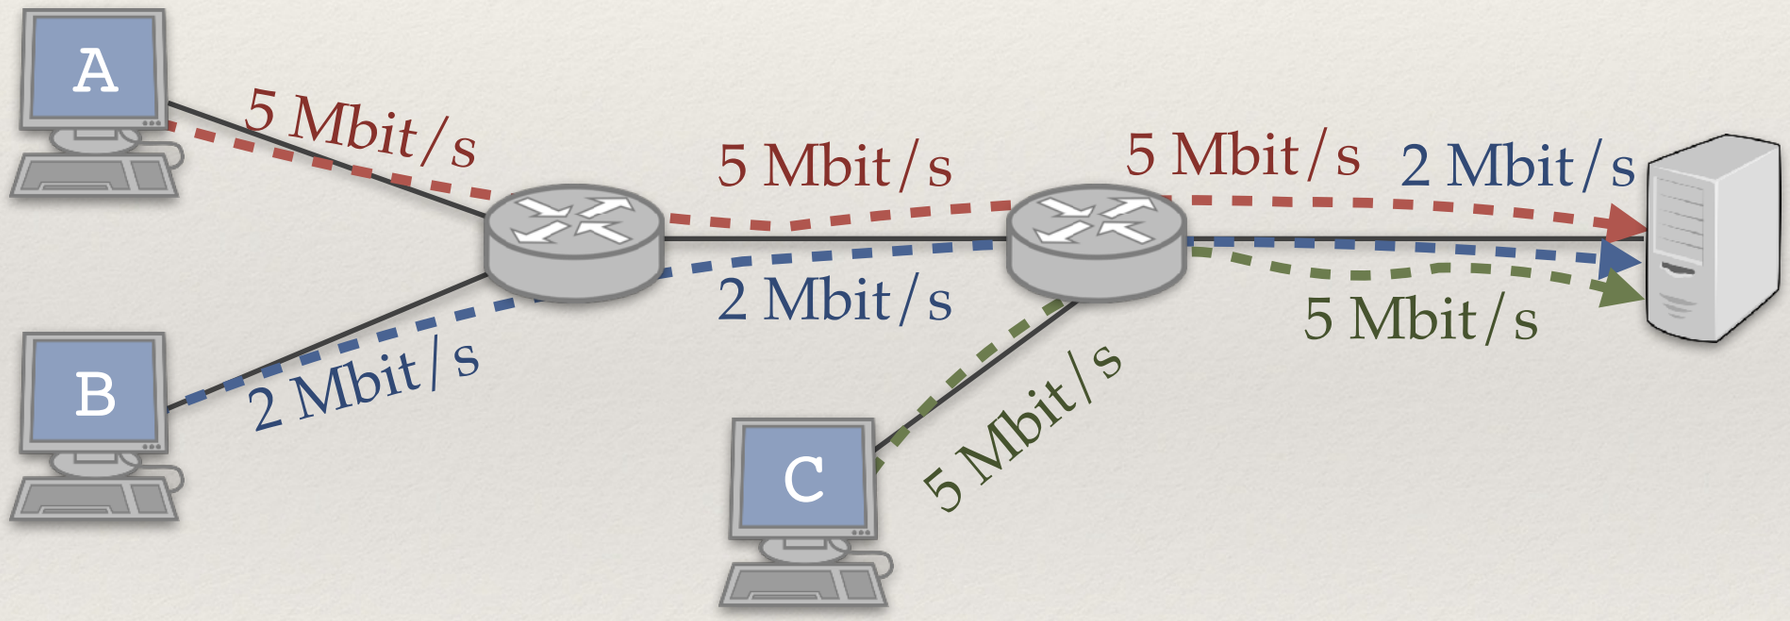


- Czy to przypisanie jest „sprawiedliwe“, czy też powinniśmy dać B proporcjonalnie mniej łącza?

# Max-Min fairness

- „Maksymalizuj minimalną przepustowość”
- Równoważnie: przypisanie jest *max-min fair,* jeśli nie można zwiększyć szybkości żadnego ze strumieni bez spowolnienia innego strumienia, który jest wolniejszy lub tak samo szybki.

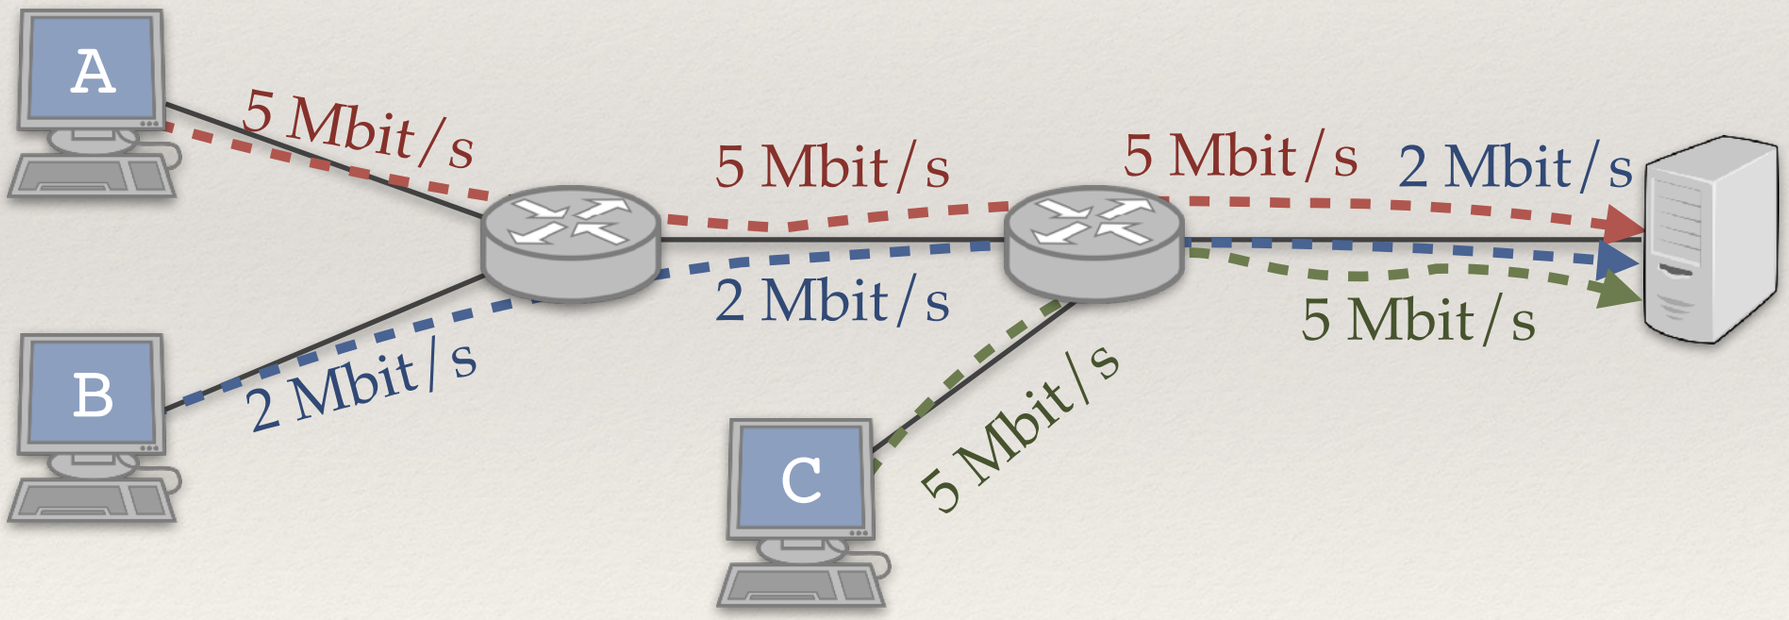

# Sprawiedliwy podział łącza vs. przepustowość

Nieoznaczone łącza mają nieskończoną przepustowość.

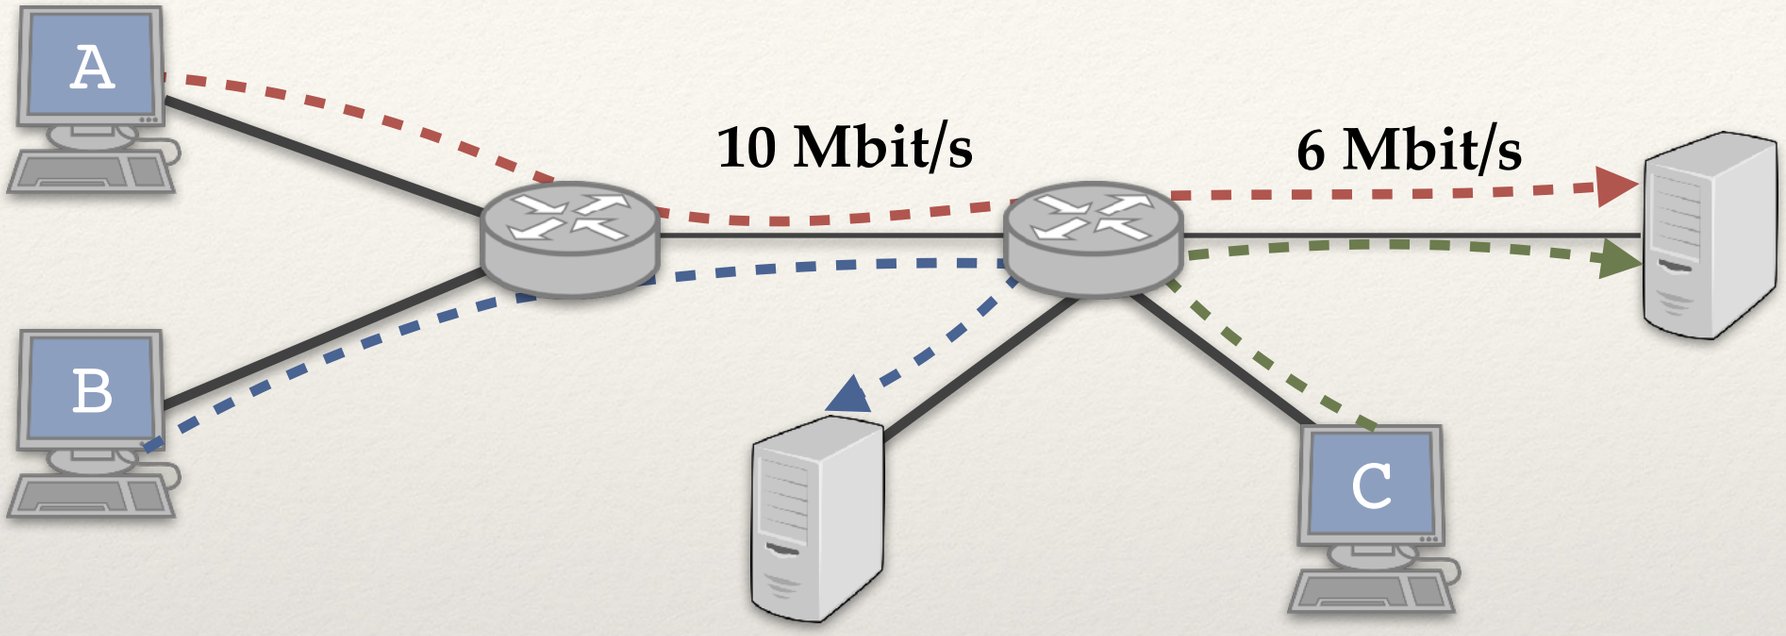


| | „sprawiedliwe“ | „niesprawiedliwe“ |
|---|---|---|
| A | 3 Mbit/s | 1 Mbit/s |
| B | 7 Mbit/s | 9 Mbit/s |
| C | 3 Mbit/s | 5 Mbit/s |
| suma | 13 Mbit/s | **15 Mbit/s** |

# AIMD

# Kontrola przeciążenia w warstwie transportowej

- Algorytm dla nadawcy.
- Wykorzystuje istniejące mechanizmy (okno przesuwne, modyfikuje rozmiar okna).
- Reaguje na obserwowane zdarzenia (utratę pakietów).
- Szacuje, ile wysłanych pakietów może bezproblemowo być „w trasie“ do celu (wysłanych i jeszcze niepotwierdzonych).

# Kontrola przepływu vs. kontrola przeciążenia

- **Kontrola przepływu = nie chcemy zalać odbiorcy danymi.**
  - SWS = oferowane okno.
- **Kontrola przeciążenia = nie chcemy zalać sieci danymi.**
  - Parametr `cwnd` (*congestion window*) obliczany przez nadawcę.
  - SWS = min { oferowane okno, `cwnd` }.
- **Będziemy zakładać, że oferowane okno = ∞.**

# AIMD (Additive Increase, Multiplicative Decrease)

- Pakiet wysłany poprawnie (otrzymaliśmy ACK):
  **cwnd ← cwnd + 1 / cwnd**.
  (W ciągu RTT wysyłane cwnd segmentów, więc cwnd zwiększa się o 1).

- Pakiet zgubiony lub opóźniony (ACK nie dociera przed RTO)
  **cwnd ← cwnd / 2.**

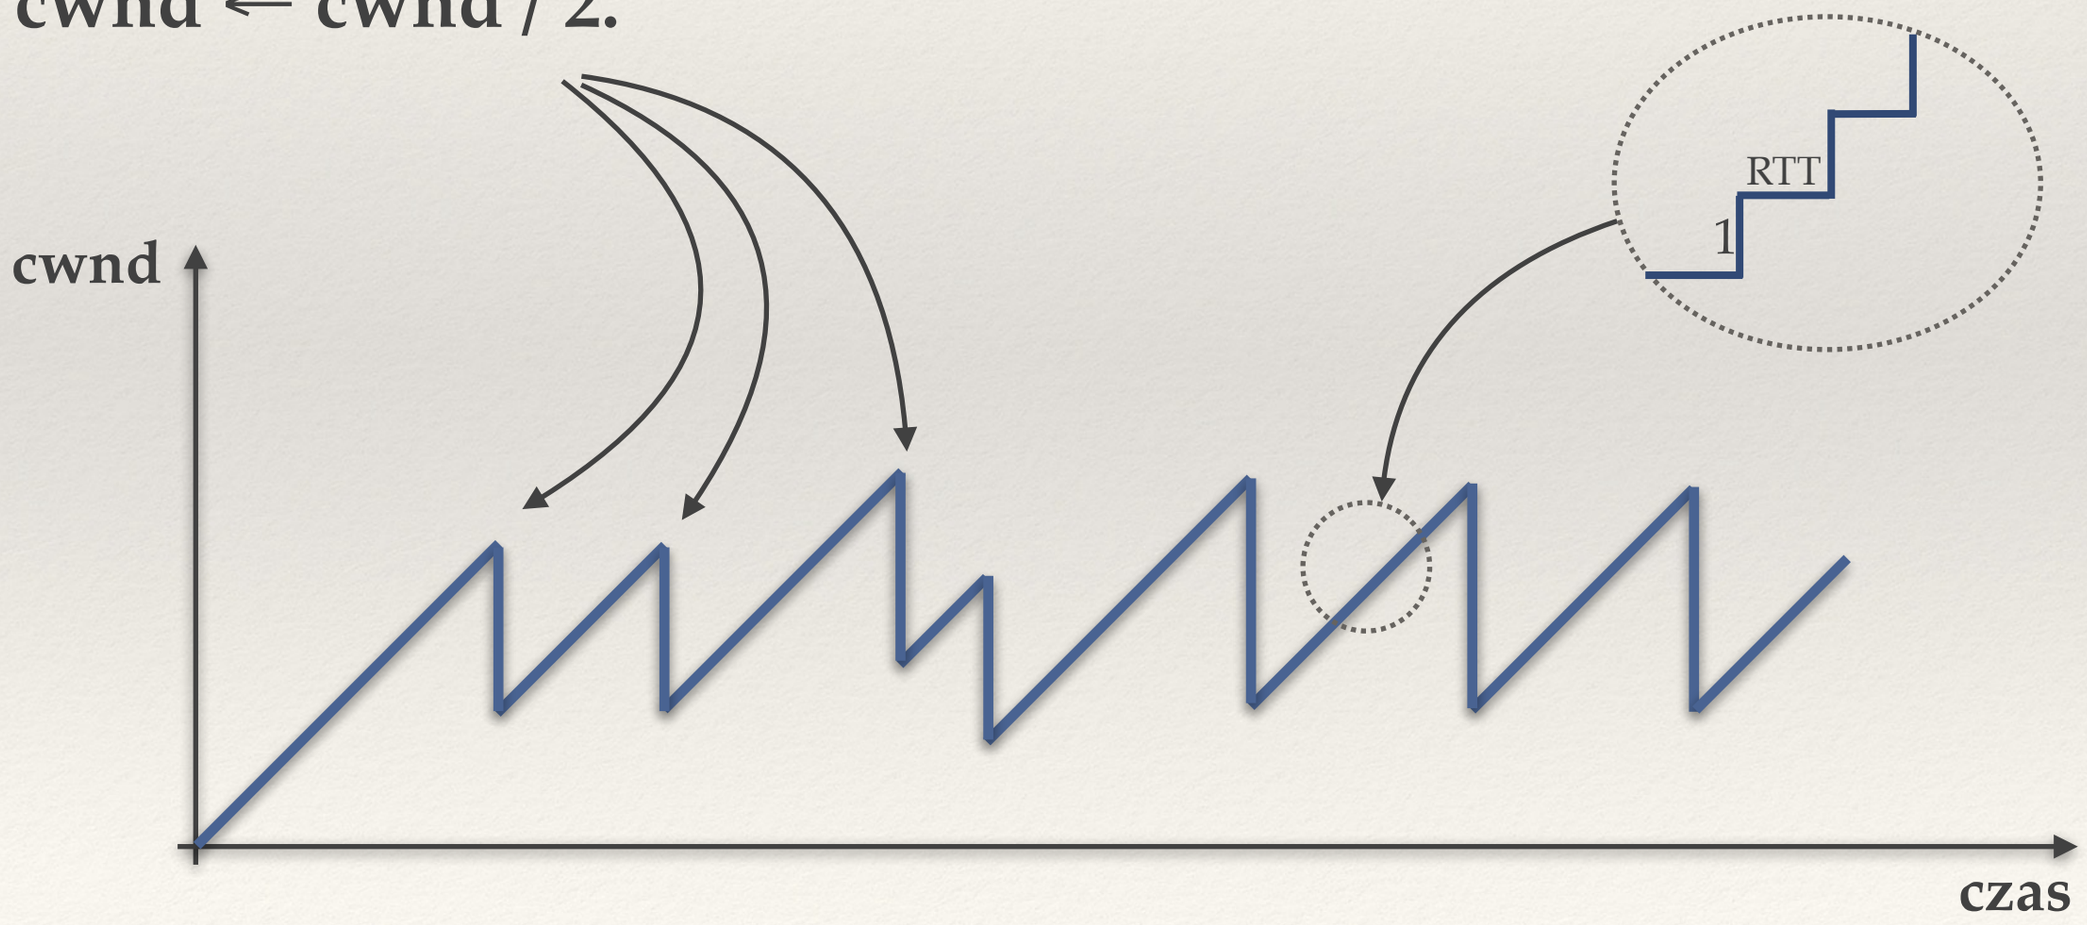

# AIMD

**Inny sposób patrzenia:**

- AIMD nie kontroluje szybkości wysyłania.
- AIMD kontroluję liczbę pakietów (danego strumienia), która jednocześnie może być w sieci.

animacje

# AIMD

**Inny sposób patrzenia:**

- AIMD nie kontroluje szybkości wysyłania.
- AIMD kontroluję liczbę pakietów (danego strumienia), która jednocześnie może być w sieci.

animacje

- Przy odpowiednio dużych buforach, najbardziej krytyczne łącze jest cały czas wykorzystane w 100%.

# AIMD vs. sprawiedliwy podział i efektywność

Własność AIMD: $A_1 \ldots A_n$ rozpoczynają transmisje do X w dowolnych momentach → ich rozmiary okien zbiegną do R/n.

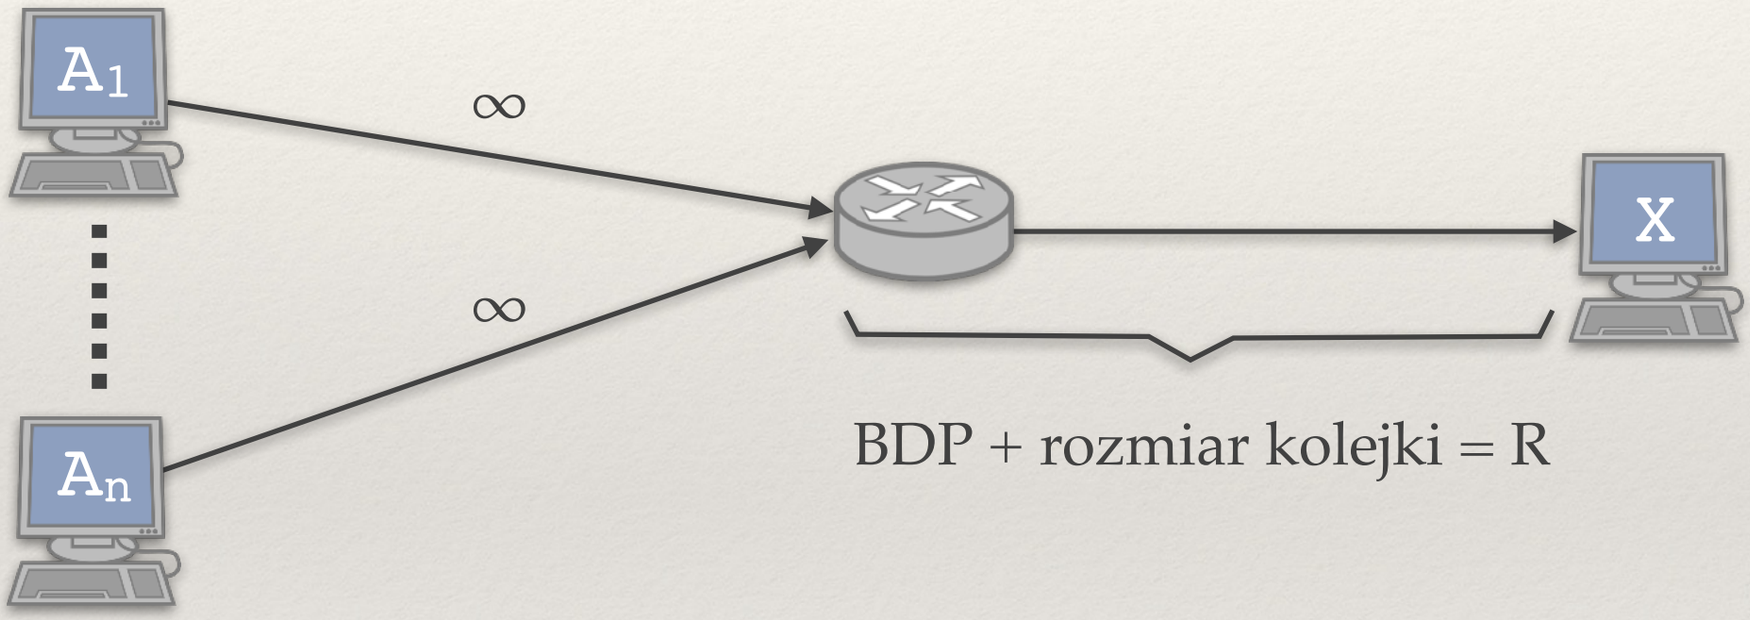


Pokażemy to dla n = 2 na obrazku.

# Sprawiedliwość podziału i efektywność (1)

- Pakiety gubią się wtedy i tylko wtedy, jeśli $\texttt{cwnd}_1 + \texttt{cwnd}_2 > R$

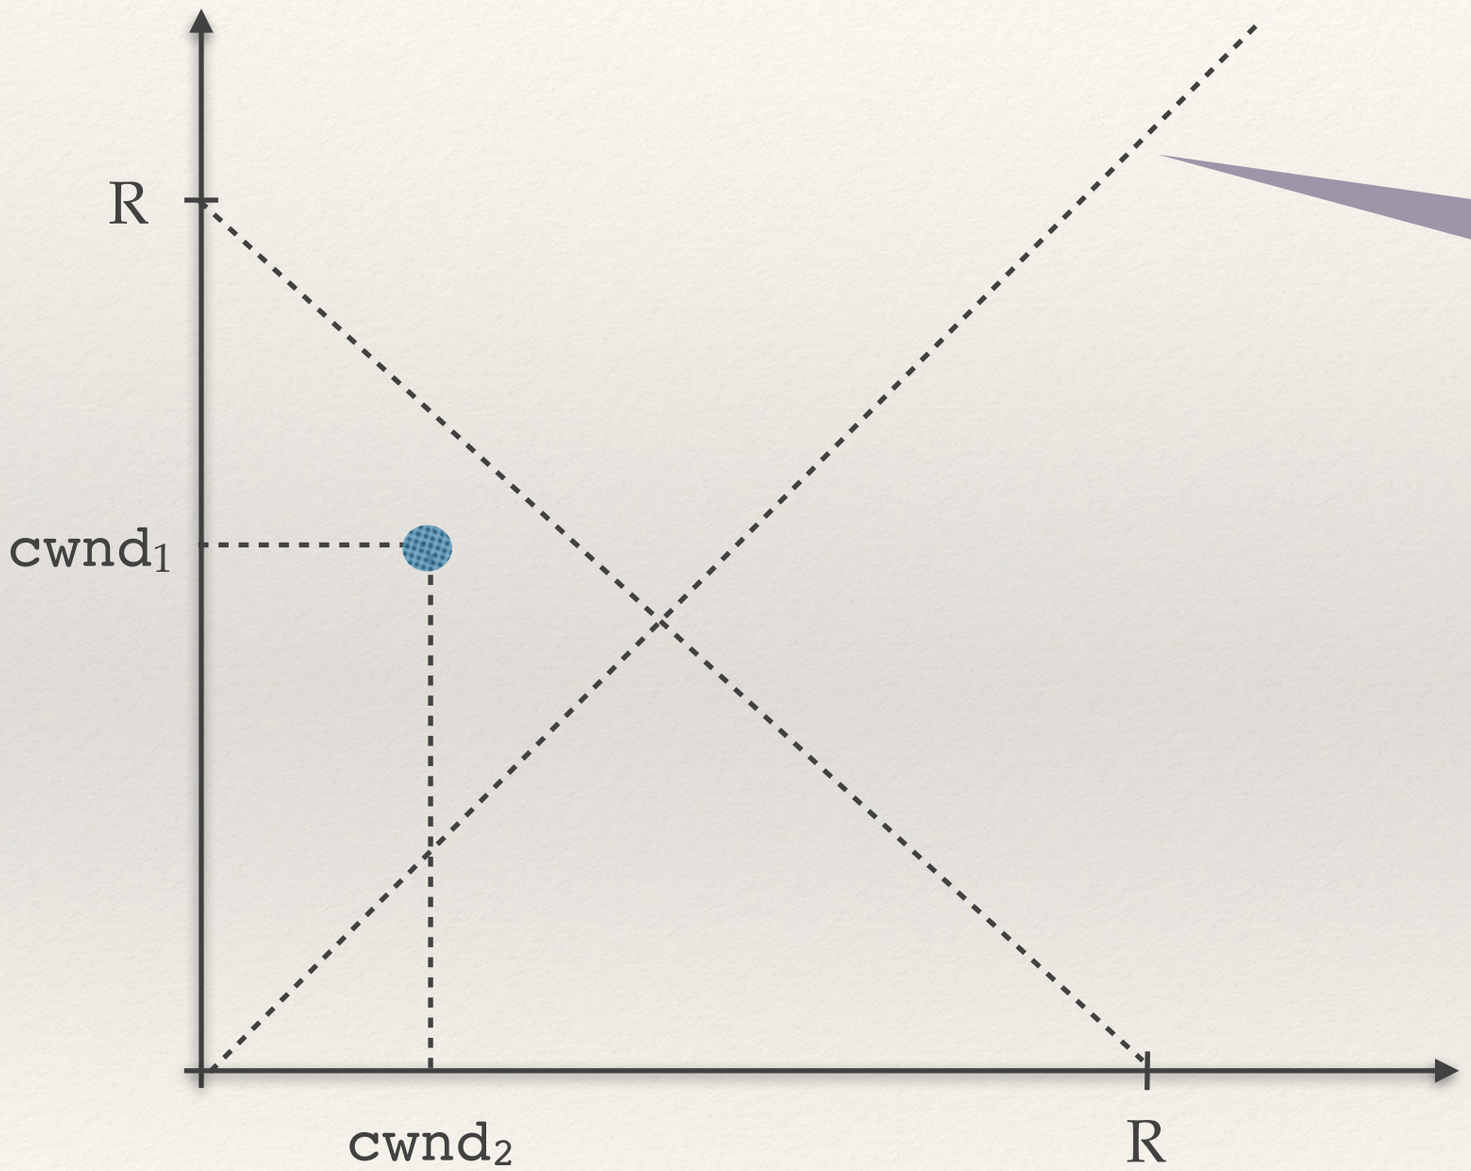


Linia sprawiedliwego podziału

# Sprawiedliwość podziału i efektywność (2)

- Rozmiary $\texttt{cwnd}_1$ i $\texttt{cwnd}_2$ jednocześnie rosną o 1 lub maleją dwukrotnie
- Docelowo mamy sprawiedliwy podział łącza i $\texttt{cwnd}_1 + \texttt{cwnd}_2$ oscylujące w przedziale [R/2, R].

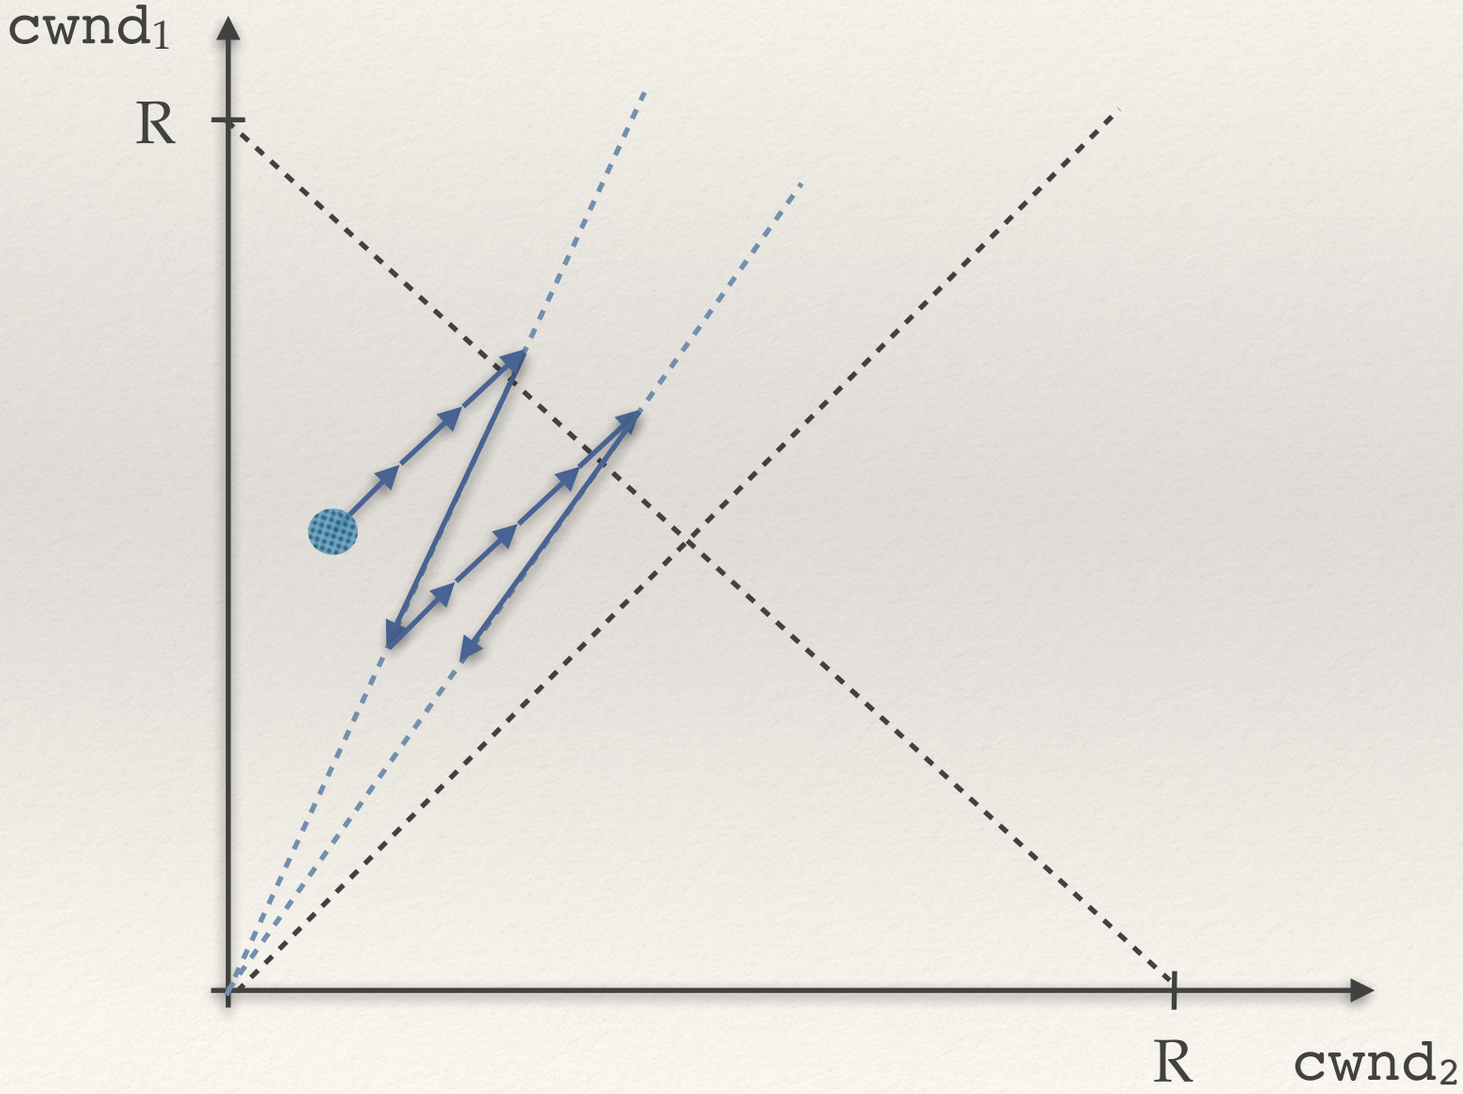

# Kontrola przeciążenia w TCP

# Kontrola przeciążenia w TCP

- **AIMD w TCP:**
  - **ACK pakietu** (explicite albo wnioskowany z potwierdzenia skumulowanego) → zwiększamy `cwnd` o MSS * MSS / `cwnd`.
    - Co RTT wysyłane jest `cwnd` / MSS segmentów: wszystkie będą potwierdzone → zwiększymy `cwnd` o MSS.
  - **Pakiet zaginął** (przekroczony timeout albo otrzymaliśmy podwójne potwierdzenie) → zmniejszamy `cwnd` dwukrotnie.

# Kontrola przeciążenia w TCP

- **AIMD w TCP:**
  - **ACK pakietu** (explicite albo wnioskowany z potwierdzenia skumulowanego) → zwiększamy `cwnd` o MSS * MSS / `cwnd`.
    - Co RTT wysyłane jest `cwnd` / MSS segmentów: wszystkie będą potwierdzone → zwiększymy `cwnd` o MSS.
  - **Pakiet zaginął** (przekroczony timeout albo otrzymaliśmy podwójne potwierdzenie) → zmniejszamy `cwnd` dwukrotnie.

**Nie do końca prawda.**
**To jest tylko faza „unikania przeciążenia“.**
**Dodatkowo TCP wprowadza fazę „wolnego startu“**

# Wolny start w TCP

- **Faza wolnego startu:**
  - Zaczynamy od `cwnd` = MSS.
  - Po każdym ACK zwiększamy `cwnd` o MSS.
    - → Co RTT `cwnd` zwiększa się dwukrotnie.
  - Faza trwa do utraty pierwszego pakietu.

- **Strata pakietu w dowolnej fazie:**
  - `ssthresh` ← `cwnd` / 2.
  - przechodzimy do fazy wolnego startu i zostajemy w niej aż `cwnd` > `ssthresh`.

# Wolny start w TCP

- **Faza wolnego startu:**
  - Zaczynamy od `cwnd` = MSS.
  - Po każdym ACK zwiększamy `cwnd` o MSS.
    - → Co RTT `cwnd` zwiększa się dwukrotnie.
  - Faza trwa do utraty pierwszego pakietu.

**Wolny start = nie ustawiamy okna od razu na oferowane przez odbiorcę.**

- **Strata pakietu w dowolnej fazie:**
  - `ssthresh` ← `cwnd` / 2.
  - przechodzimy do fazy wolnego startu i zostajemy w niej aż `cwnd` > `ssthresh`.

# AIMD w TCP: przykład

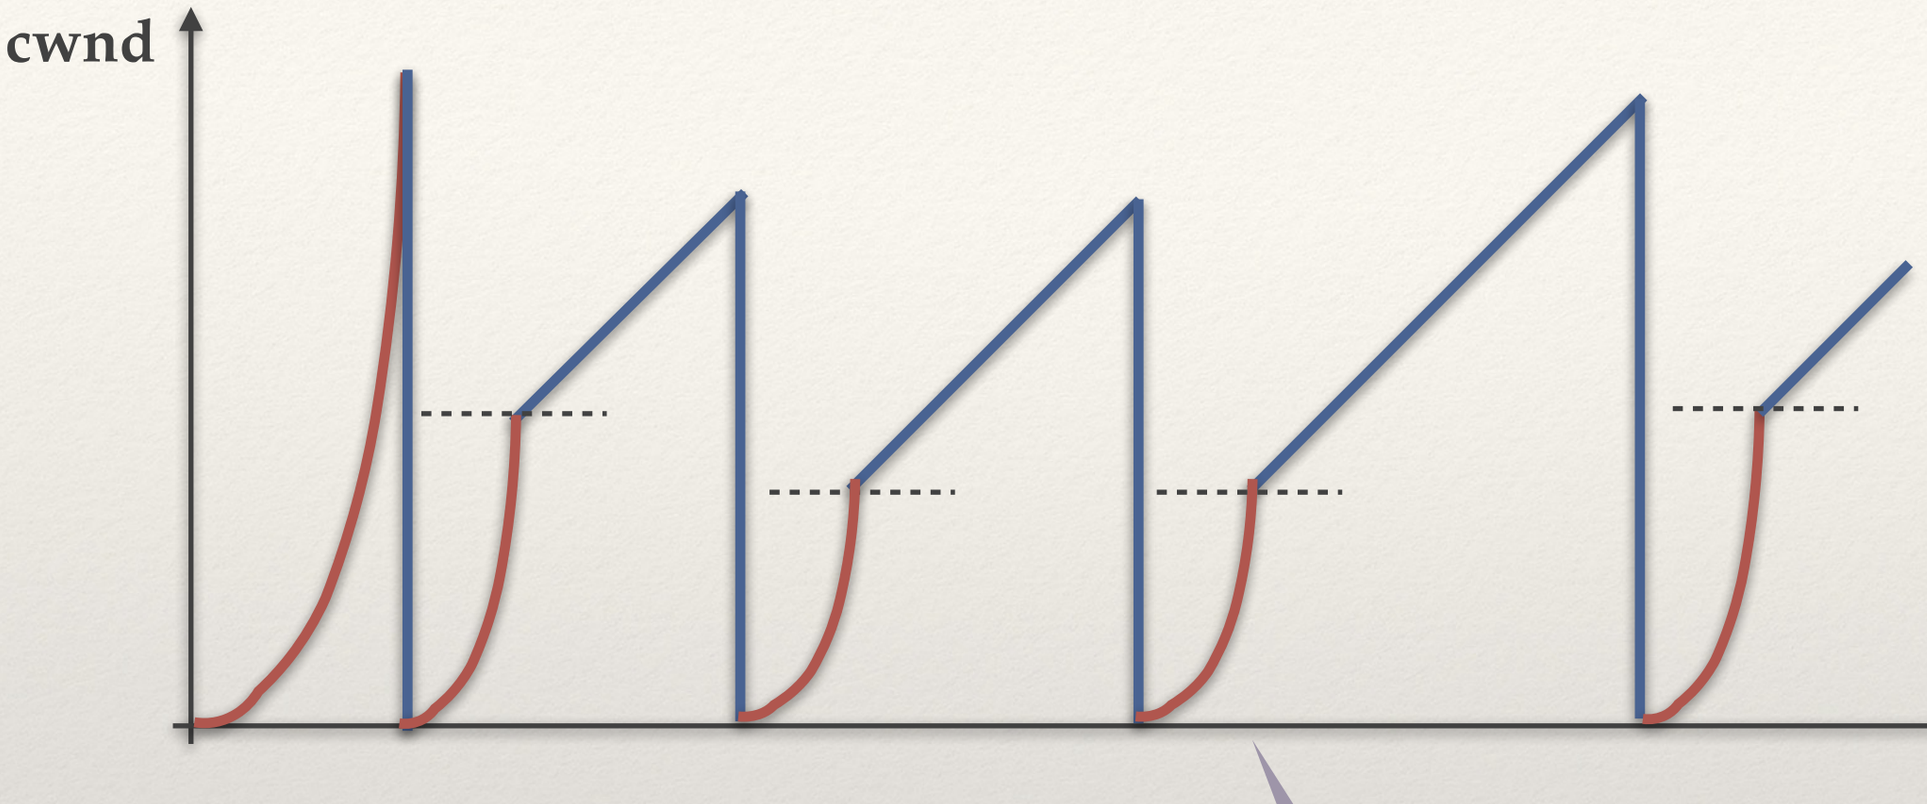


faza wolnego startu

faza unikania przeciążenia

`ssthresh`

Fazy wolnego startu mają logarytmiczną długość, poza nimi TCP wykonuje AIMD.

# Fazy w TCP: diagram przejścia

**Inicjalizacja:** faza wolnego startu, `ssthresh` = ∞, `cwnd` = MSS.

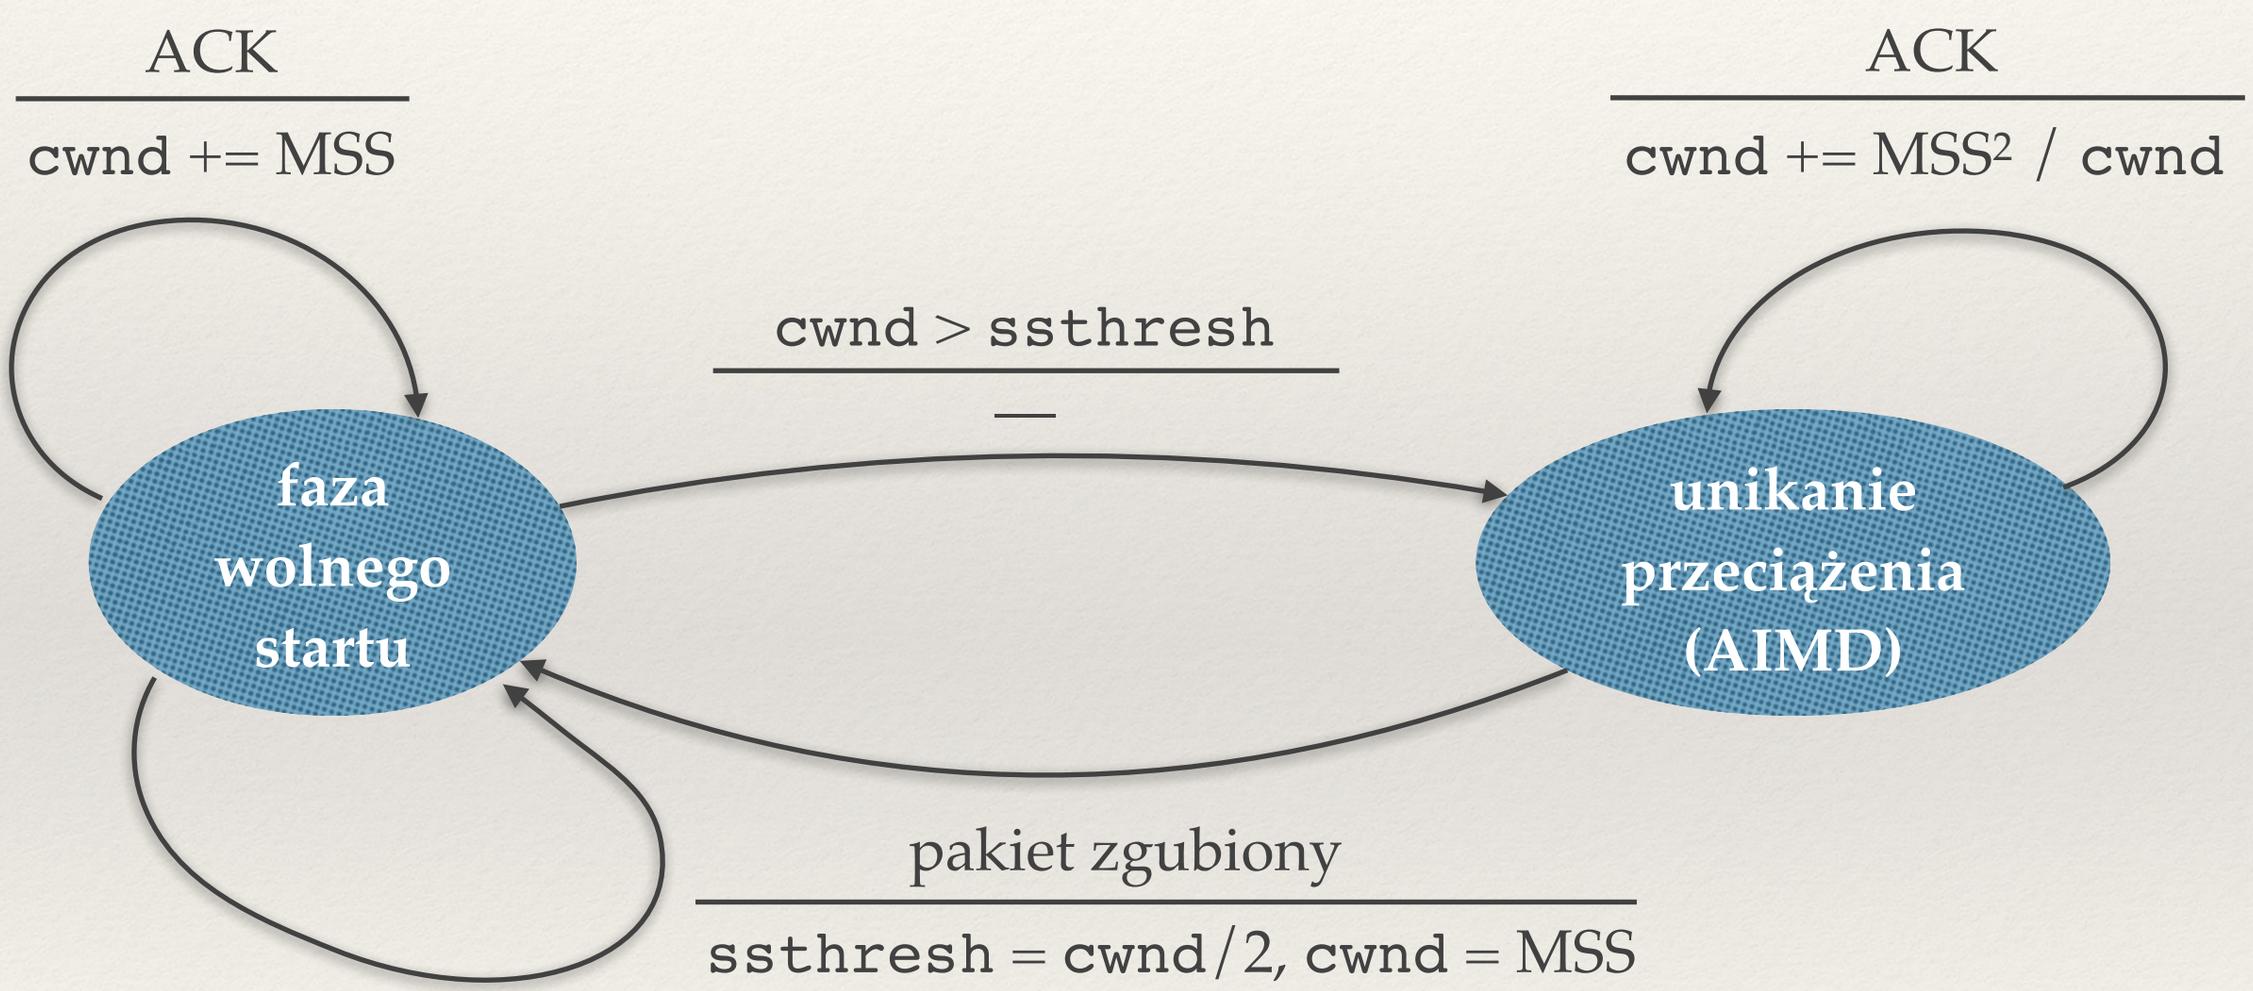

# Źródła informacji o utracie pakietu

- **Timeout dla pakietu**

- **Wielokrotny ACK**
  - Przykładowo: odbiorca dostaje segmenty 1, 2, 3, 5, 6
    → wysyła ACK 1, ACK 2, ACK 3, ACK 3, ACK 3.
  - Statystycznie mniejsza szansa, że mamy do czynienia z dłuższym przeciążeniem (kolejne pakiety doszły do odbiorcy)!
  - **Szybka retransmisja** (wysyłamy brakujący segment bez czekania na timeout).
  - **Szybkie przywracanie** (pomijamy fazę krótkiego startu): `ssthresh` = `cwnd` / 2; `cwnd` = `ssthresh`.

# Wspomaganie przez routery

# RED

**RED (Random Early Detection)**

- Router na trasie wyrzuca losowe pakiety.
- Prawdopodobieństwo wyrzucenia ustalane jako rosnąca funkcja **średniej** długości kolejki.
  - Nie reaguje na krótkotrwałe zwiększenia kolejki.

- Krótsze kolejki → mniejsze opóźnienia.
- Desynchronizacja strumieni (zmniejszają prędkości w różnych momentach).

# ECN (Explicit Congestion Notification)

- Prawdopodobne przeciążenie → router ustawia bity ECN w nagłówku IP.
- Odbiorca ustawia bity ECN w nagłówku TCP ACK.
- Nadawca reaguje tak, jak na utratę pakietu.

**nagłówek IP:**

| wersja | IHL | typ usługi | całkowita długość pakietu |
|---|---|---|---|
| pola związane z fragmentacją pakietu | | | |
| TTL | | protokół | suma kontrolna nagłówka IP |
| źródłowy adres IP | | | |
| docelowy adres IP | | | |

**nagłówek TCP:**

| port źródłowy | | | | port docelowy |
|---|---|---|---|---|
| numer sekwencyjny (numer pierwszego bajtu w segmencie) | | | | |
| numer ostatniego potwierdzanego bajtu + 1 | | | | |
| offset | 000 | ECN | U-A-P-R-S- | oferowane okno |
| suma kontrolna | | | | wskaźnik pilnych danych |
| dodatkowe opcje, np. potwierdzanie selektywne | | | | |

# Problemy z kontrolą przeciążenia

# Problemy

- Krótkie połączenia.
- Przepustowość proporcjonalna do $1/\sqrt{p}$, gdzie p jest frakcją traconych pakietów.
- Podatność na oszukiwanie.

# Krótkie połączenia

- Większość połączeń przesyła poniżej 100 KB danych.
- Nie wychodzą poza fazę wolnego startu!
- Remedium: trwałe połączenia, HTTP/2

# Przepustowość vs. straty segmentów (1)

- Rozważmy stabilny stan i pomińmy fazy wolnego startu.

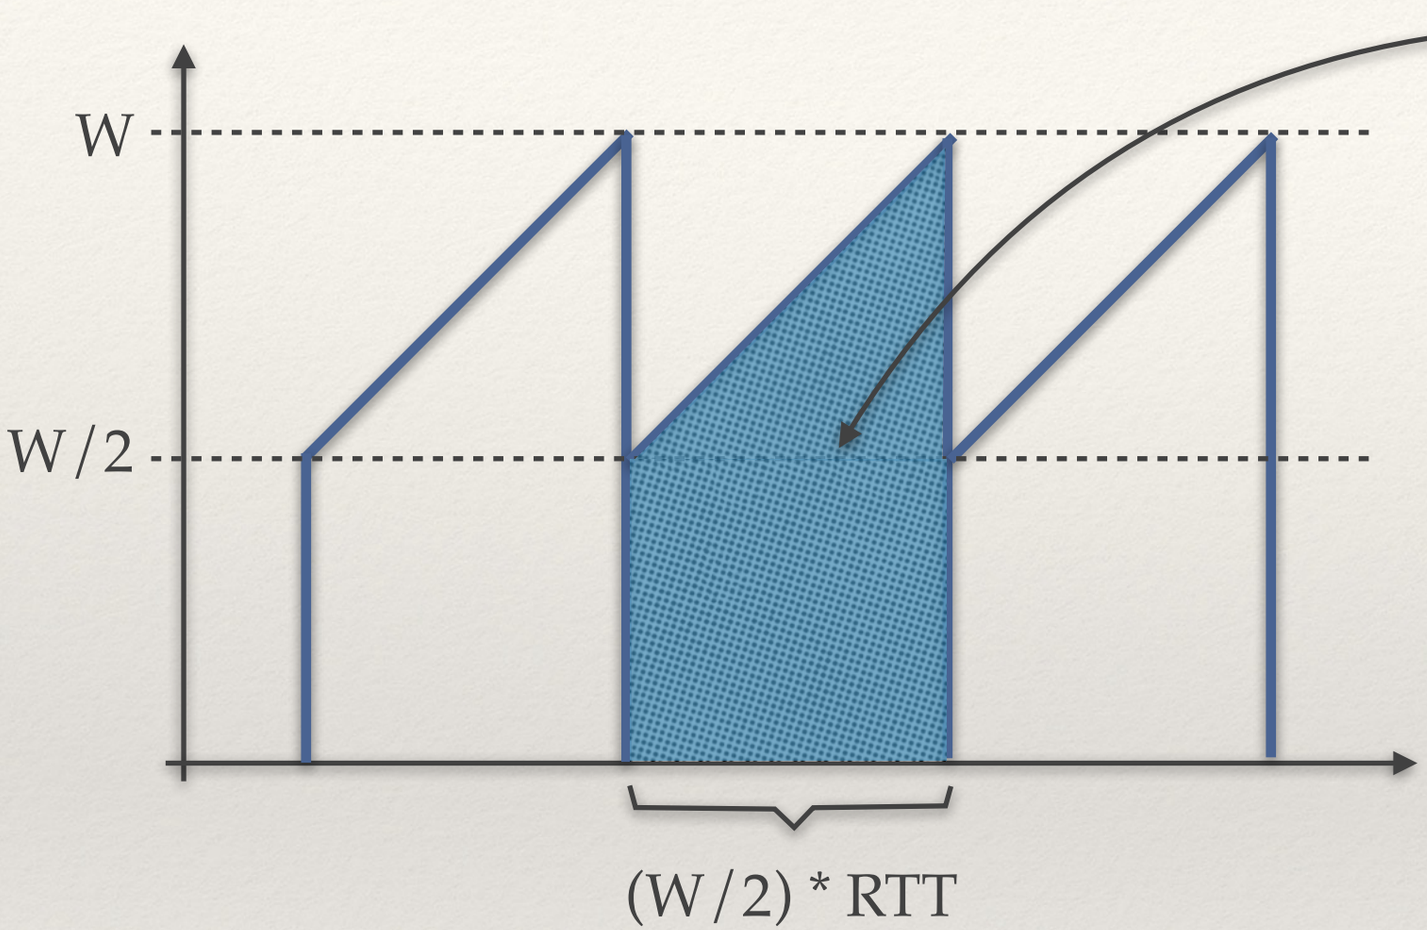


Średnio (3/4) W segmentów przesyłanych w jednym RTT.

- W jednej fazie: przesyłanych (3/8) $W^2$ segmentów, jeden gubiony.
- Średnia prędkość przesyłania: (3/4) W / RTT.

# Przepustowość vs. straty segmentów (2)

bardzo mało!

- Frakcja traconych segmentów: $p = 8/3\ (1/W^2)$.

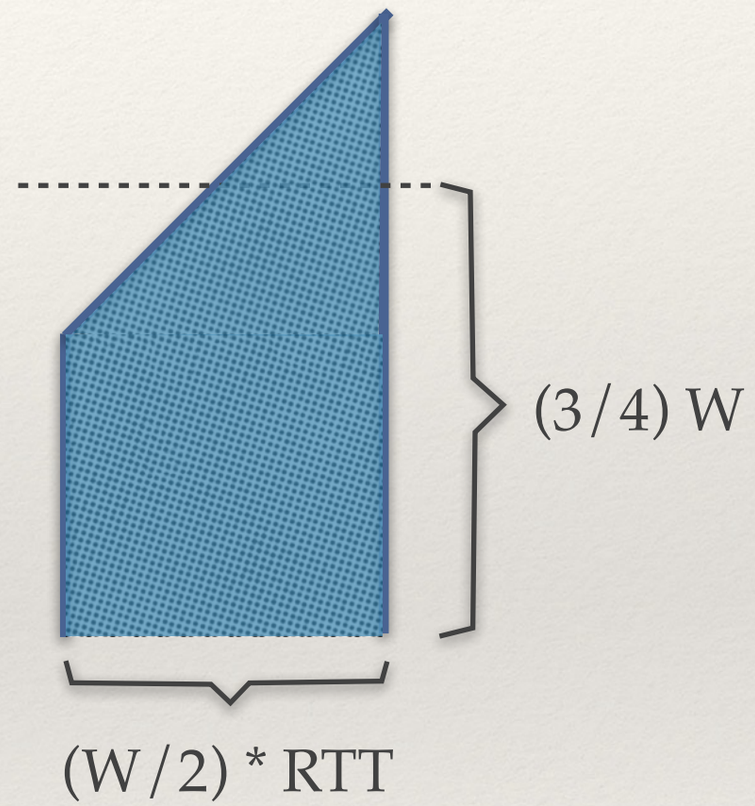

# Przepustowość vs. straty segmentów (2)

bardzo mało!

- Frakcja traconych segmentów: $p = 8/3\ (1/W^2)$.

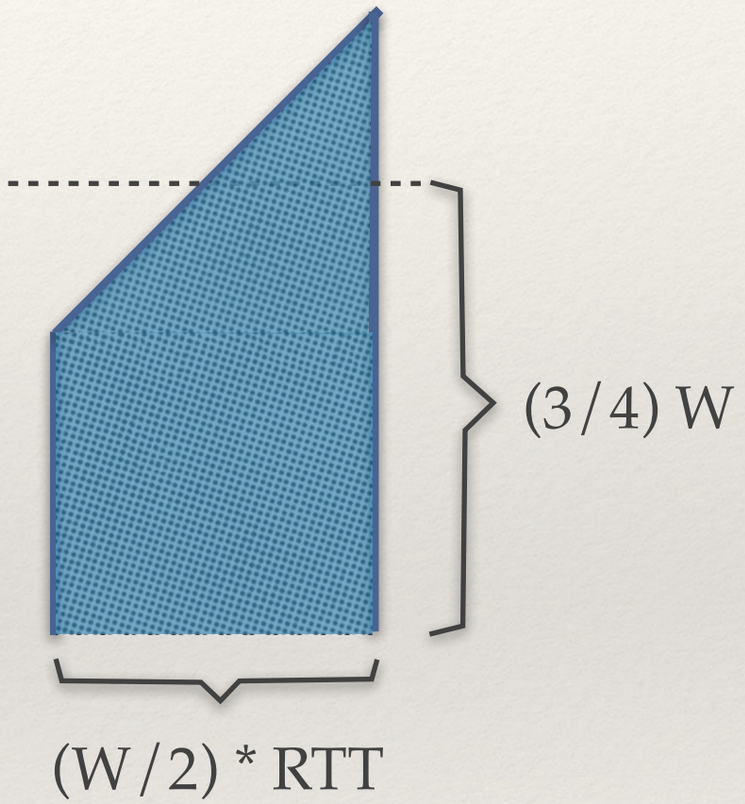


- Średnia prędkość przesyłania (segment / sek.)

$$T = \frac{3}{4} \cdot \frac{W}{\mathrm{RTT}} = \sqrt{\frac{3}{2}} \cdot \frac{1}{\mathrm{RTT} \cdot \sqrt{p}}$$

# Łącza o dużym BDP

- Prędkość przesyłania: $T = \sqrt{\frac{3}{2}} \cdot \frac{1}{\mathrm{RTT} \cdot \sqrt{p}}$ segmentów / sekundę.
- Transmisja RTT = 100 ms, MSS = 1500 bajtów, łącze 10 Gbit/s.
- Żeby osiągnąć T = 10 Gbit/s, p ≈ 2 * $10^{-10}$:
  - Co najwyżej jeden tracony segment na 2 * $10^{10}$ segmentów.
  - Nie do zrealizowania w praktyce.
- Dla takich łączy FastTCP ze zmodyfikowanym AIMD: powyżej pewnej wartości `cwnd` zwiększane szybciej i zmniejszane wolniej.

# TCP w WiFi

- Przepustowość proporcjonalna do $1/\sqrt{p}$, gdzie p jest frakcją traconych pakietów.
- Pakiety tracone niekoniecznie przez przeciążenie, np. w sieciach bezprzewodowych tracone przez interferencje!
- Żeby TCP działało sensownie konieczne są retransmisje dokonywane przez warstwy niższe (warstwę łącza danych).

# Transmisje o mniejszym RTT są preferowane

- Prędkość przesyłania: T = (3/4) W / RTT (segmentów / sek).

- Dwie transmisje korzystającego z tego samego łącza o małej przepustowości: ich okna przeciążenia (W) są takie same.

- Prędkości transmisji proporcjonalne do 1/RTT: transmisje o mniejszym RTT przesyłane szybciej!

# Nadużycia

- Zaczynanie wolnego startu z `cwnd` > 1 MSS.

- Szybsze zwiększanie `cwnd` → niesprawiedliwy podział łącza.

- Otwieranie wielu połączeń (np. aplikacje P2P), bo każde połączenie ma takie samo `cwnd`.

# Lektura dodatkowa

- Kurose & Ross: rozdział 3.
- Tanenbaum: rozdział 6.
- TCP Congestion Control RFC: `https://tools.ietf.org/html/rfc5681`
- `https://en.wikipedia.org/wiki/TCP_congestion_control`

# Zagadnienia

- Czym różni się kontrola przepływu od kontroli przeciążenia?
- Co to jest przeciążenie?
- Na czym polega mechanizm opóźnionych potwierdzeń?
- Jaka jest zależność między rozmiarem okna nadawcy a prędkością transmisji?
- Czy nieskończone bufory rozwiązałyby problem przeciążenia?
- Jak zależy średni rozmiar kolejki od średniej prędkości nadchodzenia pakietów?
- Jakie są cele kontroli przeciążenia?
- Jak można definiować sprawiedliwy podział łącza? Co to jest *max-min fairness*?
- Na jakiej podstawie zmienia się rozmiar okna przeciążenia?
- Kiedy TCP wnioskuje, że pakiet zaginął?
- Opisz algorytm ustalania rozmiaru okna przeciążenia
- Rozwiń skrót AIMD. Czego dotyczy?
- W jaki sposób AIMD gwarantuje sprawiedliwy podział łącza?
- Opisz fazy unikania przeciążenia i wolnego startu w TCP.
- Opisz mechanizm szybkiej retransmisji i szybkiego przywracania.
- Na czym polega mechanizm RED?
- Opisz działanie mechanizmu ECN (*explicit congestion notification*).
- Jaka jest relacja w AIMD między przepustowością a traconymi pakietami?
- Jakie modyfikacje wprowadza FastTCP do AIMD? Dlaczego?